Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Meneses Yaranga Nombre: Abel	27/08/2026

Detección de anomalías y técnicas de agrupamiento

Aplicación de aprendizaje no supervisado al conjunto de datos de cardiotocografía (CTG)

Asignatura: Aprendizaje Automático

Programa: Maestría en Inteligencia Artificial

Autor: Abel Meneses Yaranga

Conjunto de datos: CTG.csv, con 2 126 registros de monitoreo fetal

Entorno: Python 3.14 con pandas, scikit-learn, SciPy, matplotlib y seaborn

Código fuente:

https://github.com/amenesesy/actividad-ml-ctg

Todo el código, las figuras y los resultados numéricos que aparecen en este informe proceden de una única ejecución del cuaderno `ML_Actividad_CTG.ipynb`, con la semilla aleatoria fijada en 42 para que los resultados sean reproducibles. El repositorio enlazado contiene el cuaderno ejecutado, los scripts que lo generan y las quince figuras en su resolución original.

Contenido

0. Configuración del entorno

1. El conjunto de datos

2. Análisis descriptivo de los datos

3. Tratamiento de los valores faltantes

4. Preparación de la matriz de características

5. Detección de anomalías

6. Técnicas de agrupamiento

7. Ventajas y desventajas de cada modelo

8. Conclusiones

Referencias

El informe reproduce íntegramente el desarrollo del cuaderno. Para cada etapa se presenta primero la explicación metodológica, después el código Python comentado, a continuación la salida que produce y, por último, la interpretación de los resultados obtenidos.

Las treinta y dos celdas de código se reproducen como captura del cuaderno abierto en Google Colab, con el resaltado de sintaxis y el área de salida tal como los presenta el entorno. En las celdas que dibujan una figura la captura recoge el código y la salida de texto, y el gráfico va justo después en formato APA, con su número, su título y su nota, para que se vea a un tamaño legible y no aparezca dos veces. El cuaderno completo está disponible en el repositorio público https://github.com/amenesesy/actividad-ml-ctg.

0. Configuración del entorno

El cuaderno se ejecuta sin cambios en local o en Google Colab. La primera celda detecta el entorno, instala las librerías que falten y descarga el conjunto de datos desde el repositorio del trabajo; la ejecución completa tarda unos dos minutos.

La segunda reúne las librerías y fija la semilla aleatoria, detalle que no es menor: Isolation Forest, K-Means y el experimento de imputación son estocásticos y sin semilla fija darían cifras distintas en cada ejecución, con lo que ninguna conclusión sería verificable.

Listado 1. Celda 0.1. Preparacion del entorno y compatibilidad con Google Colab. Captura del cuaderno en Google Colab.

```python
# Celda 0.1. Preparacion del entorno y compatibilidad con Google Colab.
# Objetivo: que el cuaderno se ejecute igual en local que en Colab. Se detecta
#   el entorno, se instalan las librerias que falten y se descarga el conjunto
#   de datos del repositorio publico si no esta presente en el directorio.
# Salidas: la constante EN_COLAB y el archivo CTG.csv disponible en el disco.

import importlib.util
import pathlib
import subprocess
import sys
import urllib.request

# Deteccion del entorno. En Colab existe el paquete google.colab; fuera de
# Colab ni siquiera existe el paquete contenedor google, asi que la deteccion
# se hace con un import protegido y no con find_spec, que ahi fallaria.
try:
    import google.colab  # noqa: F401
    EN_COLAB = True
except ImportError:
    EN_COLAB = False

# Direccion base del repositorio publico del trabajo, desde donde se descargan
# los datos cuando el cuaderno se abre en un entorno recien creado.
REPO = "https://raw.githubusercontent.com/amenesesy/actividad-ml-ctg/main"

# Dependencias del cuaderno, como pares (modulo que se importa, paquete de pip).
DEPENDENCIAS = [
    ("numpy", "numpy"),
    ("pandas", "pandas"),
    ("matplotlib", "matplotlib"),
    ("seaborn", "seaborn"),
    ("sklearn", "scikit-learn"),
    ("scipy", "scipy"),
]

faltantes = [pip for modulo, pip in DEPENDENCIAS
             if importlib.util.find_spec(modulo) is None]
if faltantes:
    print("Instalando dependencias que faltan:", ", ".join(faltantes))
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", *faltantes],
                   check=True)
else:
    print("Todas las dependencias estan disponibles.")

# El conjunto de datos se descarga solo si no esta ya en el directorio actual.
if not pathlib.Path("CTG.csv").exists():
    print("Descargando CTG.csv desde el repositorio del trabajo...")
    urllib.request.urlretrieve(REPO + "/CTG.csv", "CTG.csv")

print("Entorno de ejecucion:", "Google Colab" if EN_COLAB else "instalacion local")
print("Version de Python   :", sys.version.split()[0])
print("Conjunto de datos   :", "CTG.csv disponible"
      if pathlib.Path("CTG.csv").exists() else "NO disponible")
```

```
Todas las dependencias estan disponibles.
Entorno de ejecucion: instalacion local
Version de Python   : 3.14.0
Conjunto de datos   : CTG.csv disponible
```

Listado 2. Celda 0.2. Importacion de librerias y configuracion global. Captura del cuaderno en Google Colab.

```python
# Celda 0.2. Importacion de librerias y configuracion global.
# Objetivo: cargar todas las dependencias en un unico lugar, fijar la semilla
#   aleatoria y homogeneizar el estilo de los graficos.
# Salidas: las constantes globales SEMILLA y DIR_FIGURAS, y el diccionario RES
#   en el que cada seccion va depositando sus resultados numericos.

# Utilidades del sistema
import json                      # serializacion de los resultados a disco
import pathlib                   # manejo de rutas independiente del sistema
import warnings                  # control de avisos no criticos

# Manipulacion de datos
import numpy as np               # algebra vectorial y generacion aleatoria
import pandas as pd              # estructuras tabulares (DataFrame)

# Visualizacion
import matplotlib.pyplot as plt  # motor de graficos de bajo nivel
import seaborn as sns            # graficos estadisticos de alto nivel

# Preprocesamiento
from sklearn.preprocessing import StandardScaler      # z = (x - mu) / sigma
from sklearn.impute import SimpleImputer, KNNImputer  # estrategias de imputacion

# Deteccion de anomalias
from sklearn.ensemble import IsolationForest          # aislamiento por particiones
from sklearn.neighbors import LocalOutlierFactor      # densidad local relativa
from sklearn.covariance import MinCovDet              # covarianza robusta (MCD)

# Agrupamiento
from sklearn.cluster import KMeans, DBSCAN, AgglomerativeClustering
from scipy.cluster.hierarchy import dendrogram, linkage

# Reduccion de dimensionalidad, vecindades y metricas
from sklearn.decomposition import PCA
from sklearn.neighbors import NearestNeighbors
from sklearn.metrics import (
    silhouette_score,             # cohesion frente a separacion (validacion interna)
    silhouette_samples,           # silueta calculada por observacion
    davies_bouldin_score,         # razon dispersion/separacion (menor es mejor)
    calinski_harabasz_score,      # razon de varianzas entre/intra (mayor es mejor)
    adjusted_rand_score,          # concordancia con etiquetas (validacion externa)
    normalized_mutual_info_score, # informacion mutua normalizada
)
from scipy import stats           # pruebas estadisticas (Kolmogorov-Smirnov, chi2)

# Configuracion global del cuaderno
SEMILLA = 42                                # unica fuente de aleatoriedad
np.random.seed(SEMILLA)
warnings.filterwarnings("ignore")           # silencia avisos de version
pd.set_option("display.width", 140)         # ancho de impresion de los DataFrame
pd.set_option("display.max_columns", 50)

# Paleta institucional, tomada de la plantilla Word de la actividad: el cian
# corporativo, los dos grises del texto y del pie, y dos tonos de apoyo para las
# escalas de gravedad clinica.
```

```python
UNIR_CIAN = "#0098CD"      # color corporativo
UNIR_CIAN_OSC = "#006E96"  # variante oscura, para segundas series
UNIR_CIAN_CLA = "#7FD0EC"  # variante clara
UNIR_GRIS = "#777777"      # gris del pie de pagina
UNIR_GRIS_OSC = "#333333"  # color del texto normal
UNIR_AMBAR = "#E8A33D"     # nivel intermedio en las escalas de gravedad
UNIR_ROJO = "#C1272D"      # nivel alto en las escalas de gravedad

PALETA_UNIR = [UNIR_CIAN, UNIR_ROJO, UNIR_GRIS, UNIR_CIAN_OSC, UNIR_AMBAR,
               UNIR_GRIS_OSC, UNIR_CIAN_CLA]

# Mapas de color derivados de la misma paleta. El divergente se usa en las
# matrices de correlacion y de centroides; el secuencial, en la matriz de
# concordancia entre detectores.
from matplotlib.colors import LinearSegmentedColormap
CMAP_DIV = LinearSegmentedColormap.from_list(
    "unir_div", [UNIR_CIAN_OSC, UNIR_CIAN, "#FFFFFF", "#E38B8E", UNIR_ROJO])
CMAP_SEQ = LinearSegmentedColormap.from_list(
    "unir_seq", ["#FFFFFF", UNIR_CIAN_CLA, UNIR_CIAN, UNIR_CIAN_OSC])

sns.set_theme(style="whitegrid", palette=PALETA_UNIR)   # estilo institucional
plt.rcParams["text.color"] = UNIR_GRIS_OSC
plt.rcParams["axes.labelcolor"] = UNIR_GRIS_OSC
plt.rcParams["axes.titlecolor"] = UNIR_GRIS_OSC
plt.rcParams["xtick.color"] = UNIR_GRIS_OSC
plt.rcParams["ytick.color"] = UNIR_GRIS_OSC
plt.rcParams["figure.dpi"] = 110
plt.rcParams["savefig.dpi"] = 200      # resolucion suficiente para imprimir
plt.rcParams["savefig.bbox"] = "tight"
# Tipografia holgada dentro de las figuras. Las figuras se disenan compactas y
# con letra grande para que sigan siendo legibles cuando el informe en PDF las
# reduce al ancho de la caja de texto.
plt.rcParams["font.size"] = 11
plt.rcParams["axes.titlesize"] = 12
plt.rcParams["axes.labelsize"] = 11
plt.rcParams["xtick.labelsize"] = 10
plt.rcParams["ytick.labelsize"] = 10
plt.rcParams["legend.fontsize"] = 10

DIR_FIGURAS = pathlib.Path("figuras")         # carpeta destino de las figuras
DIR_FIGURAS.mkdir(exist_ok=True)

# Diccionario acumulador. Cada seccion deposita aqui sus resultados numericos
# para que el informe en PDF se construya despues a partir de datos reales y no
# de cifras transcritas a mano.
RES = {}


def guardar(nombre):
    """Guarda la figura activa de matplotlib en figuras/<nombre>.png y la muestra.

    Parametros
    ----------
    nombre : str
        Nombre del archivo destino, sin extension ni ruta.
    """
    plt.savefig(DIR_FIGURAS / (nombre + ".png"))
    plt.show()


print("Librerias cargadas correctamente. Semilla aleatoria fijada en", SEMILLA)
```

```
Librerias cargadas correctamente. Semilla aleatoria fijada en 42
```

1. El conjunto de datos

1.1 Contexto del problema

La cardiotocografía registra a la vez la frecuencia cardiaca del feto y la actividad contráctil del útero durante el embarazo tardío y el parto. Su interpretación visual tiene una concordancia entre observadores notoriamente baja, y por eso desde los años noventa existen sistemas que resumen cada trazado en un vector de descriptores numéricos.

El archivo **`CTG.csv`** es el resultado de aplicar el sistema SisPorto 2.0 (Ayres-de-Campos et al., 2000) a 2 126 trazados: cada fila es un segmento de registro y cada columna un descriptor automático. Tres obstetras etiquetaron además cada segmento con **`CLASS`**, el patrón morfológico en diez categorías, y **`NSP`**, el estado fetal en tres niveles: normal, sospechoso y patológico.

1.2 Por qué este conjunto se ajusta a la actividad

El problema encaja con las dos técnicas que pide el enunciado. Los casos patológicos son minoritarios, apenas el 8,3 % del total, de modo que un buen detector de atípicos debería enriquecerse en ellos sin haberlos visto nunca: eso permite medir de forma objetiva si resulta útil y no solo si es matemáticamente correcto. Y si la frecuencia cardiaca fetal presenta patrones morfológicos diferenciados, un algoritmo de agrupamiento debería recuperarlos al menos en parte; el contraste posterior con **`NSP`** cuantifica cuánta de esa estructura es real y cuánta un

artefacto del algoritmo.

Listado 3. Celda 1.1. Carga del conjunto de datos. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 1.1. Carga del conjunto de datos.
# Se usa la copia local que dejo preparada la celda 0.1 y, si por lo que fuera
# no estuviera, se recurre al archivo original publicado por el curso.
# Salidas: df_bruto, con los datos tal y como vienen del archivo.

RUTA_LOCAL = pathlib.Path("CTG.csv")
URL_CURSO = ("https://raw.githubusercontent.com/OscarJimenezFlores/ML/"
             "refs/heads/main/Data/CTG.csv")

origen = RUTA_LOCAL if RUTA_LOCAL.exists() else URL_CURSO
df_bruto = pd.read_csv(origen)

print("Origen de los datos          :", origen)
print("Dimensiones (filas, columnas):", df_bruto.shape)
print("\nPrimeras 3 filas:")
df_bruto.head(3)
```

```
Origen de los datos          : CTG.csv
Dimensiones (filas, columnas): (2129, 40)

Primeras 3 filas:
```

	FileName	Date	SegFile	b	e	LBE	LB	AC	FM	UC	ASTV	MSTV	ALTV	MLTV	DL	DS	DP	DR	Width	Min	Max	Nmax	Nzeros	Mode	Mean	Median
0	Variab10.txt	12/1/1996	CTG0001.txt	240.0	357.0	120.0	120.0	0.0	0.0	0.0	73.0	0.5	43.0	2.4	0.0	0.0	0.0	0.0	64.0	62.0	126.0	2.0	0.0	120.0	137.0	121.0
1	Fmcs_1.txt	5/3/1996	CTG0002.txt	5.0	632.0	132.0	132.0	4.0	0.0	4.0	17.0	2.1	0.0	10.4	2.0	0.0	0.0	0.0	130.0	68.0	198.0	6.0	1.0	141.0	136.0	140.0
2	Fmcs_1.txt	5/3/1996	CTG0003.txt	177.0	779.0	133.0	133.0	2.0	0.0	5.0	16.0	2.1	0.0	13.4	2.0	0.0	0.0	0.0	130.0	68.0	198.0	5.0	1.0	141.0	135.0	138.0

Antes de calcular ningún estadístico conviene documentar qué significa cada columna y qué papel juega. Sin ese paso el análisis se vuelve estadística ciega: no hay forma de decidir qué variables son informativas, cuáles simples identificadores, cuáles duplican información y cuáles son etiquetas que deben quedar apartadas del modelado.

Listado 4. Celda 1.2. Diccionario de variables. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 1.2. Diccionario de variables.
# Documenta el significado y el rol de cada una de las 40 columnas del archivo.
# Salidas: el diccionario DICCIONARIO y la tabla legible tabla_dic.

DICCIONARIO = {
    # Identificadores del registro, sin valor descriptivo
    "FileName": ("Identificador", "Nombre del archivo del trazado original"),
    "Date":     ("Identificador", "Fecha del registro"),
    "SegFile":  ("Identificador", "Nombre del segmento analizado"),
    "b":        ("Identificador", "Indice de inicio del segmento en el trazado"),
    "e":        ("Identificador", "Indice de fin del segmento en el trazado"),
    # Descriptores de la frecuencia cardiaca fetal
    "LBE":      ("Redundante",    "Linea de base de la FCF segun el experto medico"),
    "LB":       ("Numerica",      "Linea de base de la FCF calculada por SisPorto (lpm)"),
    "AC":       ("Numerica",      "Numero de aceleraciones"),
    "FM":       ("Numerica",      "Numero de movimientos fetales"),
    "UC":       ("Numerica",      "Numero de contracciones uterinas"),
    "ASTV":     ("Numerica",      "% de tiempo con variabilidad anormal a corto plazo"),
    "MSTV":     ("Numerica",      "Valor medio de la variabilidad a corto plazo"),
    "ALTV":     ("Numerica",      "% de tiempo con variabilidad anormal a largo plazo"),
    "MLTV":     ("Numerica",      "Valor medio de la variabilidad a largo plazo"),
    "DL":       ("Numerica",      "Numero de deceleraciones ligeras"),
    "DS":       ("Numerica",      "Numero de deceleraciones severas"),
    "DP":       ("Numerica",      "Numero de deceleraciones prolongadas"),
    "DR":       ("Constante",     "Numero de deceleraciones repetitivas (siempre 0)"),
    # Descriptores del histograma de la frecuencia cardiaca fetal
    "Width":    ("Numerica",      "Amplitud del histograma de la FCF"),
    "Min":      ("Numerica",      "Valor minimo del histograma"),
    "Max":      ("Numerica",      "Valor maximo del histograma"),
    "Nmax":     ("Numerica",      "Numero de picos del histograma"),
    "Nzeros":   ("Numerica",      "Numero de ceros del histograma"),
    "Mode":     ("Numerica",      "Moda del histograma"),
    "Mean":     ("Numerica",      "Media del histograma"),
    "Median":   ("Numerica",      "Mediana del histograma"),
    "Variance": ("Numerica",      "Varianza del histograma"),
    "Tendency": ("Ordinal",       "Tendencia del histograma (-1 izq., 0 simetrica, 1 der.)"),
    # Codificacion disyuntiva (one-hot) de la etiqueta CLASS
    **{c: ("One-hot de CLASS", "Indicador binario del patron morfologico " + c)
       for c in ["A", "B", "C", "D", "E", "AD", "DE", "LD", "FS", "SUSP"]},
    # Etiquetas de diagnostico, reservadas como verdad de referencia
    "CLASS":    ("Etiqueta", "Patron morfologico de la FCF (10 categorias)"),
    "NSP":      ("Etiqueta", "Estado fetal: 1=Normal, 2=Sospechoso, 3=Patologico"),
}

tabla_dic = pd.DataFrame(
    [(v, r, d) for v, (r, d) in DICCIONARIO.items()],
    columns=["Variable", "Rol", "Descripcion"],
)

[ ]
print("Columnas documentadas:", len(tabla_dic), "| reparto por rol:")
for rol, n in tabla_dic["Rol"].value_counts().items():
    ejemplos = ", ".join(tabla_dic.loc[tabla_dic["Rol"] == rol, "Variable"].head(4))
    print("  %-18s %2d   (%s%s)" % (rol, n, ejemplos, ", ..." if n > 4 else ""))

RES["n columnas"] = int(df_bruto.shape[1])
```

```
Columnas documentadas: 40 | reparto por rol:
  Numerica           20   (LB, AC, FM, UC, ...)
  One-hot de CLASS   10   (A, B, C, D, ...)
  Identificador       5   (FileName, Date, SegFile, b, ...)
  Etiqueta            2   (CLASS, NSP)
  Redundante          1   (LBE)
  Constante           1   (DR)
  Ordinal             1   (Tendency)
```

El reparto por rol deja ver que el archivo contiene menos información de la que sugieren sus 40 columnas: cinco identifican el registro, una duplica a otra, otra es constante, diez recodifican la

etiqueta **`CLASS`** y dos son las propias etiquetas. Solo veintiuna describen el trazado, y en la sección 4 se verá que incluso entre esas hay una redundancia exacta.

2. Análisis descriptivo de los datos

El análisis exploratorio persigue tres objetivos antes de aplicar ningún algoritmo: conocer la escala y la forma de cada variable, porque la detección de anomalías y el agrupamiento se basan en distancias y son sensibles a las unidades y a la asimetría; detectar los problemas de calidad, es decir, filas espurias, columnas constantes, duplicados y redundancias que contaminarían los modelos; y cuantificar la redundancia mediante la matriz de correlaciones, dato decisivo para saber si conviene reducir la dimensionalidad.

2.1 Estructura del conjunto

Listado 5. Celda 2.1. Estructura general del conjunto de datos. Captura del cuaderno en Google Colab.

```python
# Celda 2.1. Estructura general del conjunto de datos.
# Objetivo: inspeccionar dimensiones, tipos de dato, memoria y duplicados. Es el
#   primer control de calidad, y cualquier anomalia estructural debe detectarse
#   aqui y no cuando ya estan fallando los modelos.

print("Dimensiones: %d filas x %d columnas (%.1f KB)"
      % (df_bruto.shape[0], df_bruto.shape[1],
         df_bruto.memory_usage(deep=True).sum() / 1024))

# Reparto de tipos de dato y filas repetidas. Un duplicado exacto en un conjunto
# de senales clinicas seria sospechoso de un error de exportacion.
tipos = ", ".join("%s=%d" % (t, n) for t, n in df_bruto.dtypes.value_counts().items())
print("Tipos de dato:", tipos)
print("Filas exactamente duplicadas:", int(df_bruto.duplicated().sum()))

# Ultimas filas del archivo: es donde suelen aparecer los artefactos de las
# hojas de calculo originales, como filas de resumen o separadores en blanco.
print("\nUltimas 4 filas del archivo (columnas 8 a 17):")
print(df_bruto.iloc[-4:, 8:18].to_string())
```

```
Dimensiones: 2129 filas x 40 columnas (985.9 KB)
Tipos de dato: float64=37, str=3
Filas exactamente duplicadas: 0

Ultimas 4 filas del archivo (columnas 8 a 17):
        FM    UC  ASTV  MSTV  ALTV  MLTV    DL   DS   DP   DR
2125   1.0   5.0  74.0   0.4  36.0   5.0   0.0  0.0  0.0  0.0
2126   NaN   NaN   NaN   NaN   NaN   NaN   NaN  NaN  NaN  NaN
2127   NaN   NaN   NaN   NaN   NaN   NaN   0.0  0.0  0.0  0.0
2128 564.0  23.0  87.0   7.0  91.0  50.7  16.0  1.0  4.0  0.0
```

La inspección de las últimas filas revela el primer hallazgo del trabajo: el archivo no termina en un registro clínico. Las tres últimas líneas son residuos de la hoja de cálculo original **`CTG.xls`**, una vacía, otra con ceros y una tercera que repite el valor máximo de cada columna. No son pacientes, sino las filas de resumen que la hoja dejó al pie, y son exactamente las que generan todos los valores faltantes del conjunto.

2.2 Estadísticos descriptivos de las variables numéricas

Listado 6. Celda 2.2. Estadisticos descriptivos de las variables numericas. Captura del cuaderno en Google Colab.

```python
# Celda 2.2. Estadisticos descriptivos de las variables numericas.
# Objetivo: obtener tendencia central, dispersion y forma de cada variable. A
#   los descriptivos clasicos se anaden la asimetria y la curtosis, que son las
#   medidas que anticipan como se comportaran los detectores de anomalias
#   basados en la hipotesis de normalidad.
# Salidas: el DataFrame desc, con una fila por variable.

# Se excluyen las columnas de texto; el resto son numericas.
num_bruto = df_bruto.select_dtypes(include=[np.number])

# describe() entrega conteo, media, desviacion, minimo, cuartiles y maximo.
desc = num_bruto.describe().T

# Asimetria: 0 indica simetria; un valor absoluto mayor que 1 indica cola marcada.
desc["asimetria"] = num_bruto.skew()
# Curtosis de Fisher: 0 es la normal; por encima de 3 hay colas muy pesadas.
desc["curtosis"] = num_bruto.kurtosis()
# Coeficiente de variacion: dispersion relativa, comparable entre variables.
desc["cv"] = desc["std"] / desc["mean"].replace(0, np.nan)

desc = desc.round(2)

# Los descriptivos se calculan para las 37 columnas numericas, pero se imprime
# una seleccion de doce que cubre los tres aspectos que se comentan despues: el
# conteo irregular, la disparidad de escalas y la asimetria de los conteos.
SELECCION = ["LB", "AC", "ASTV", "MSTV", "ALTV", "MLTV",
             "DS", "DP", "Width", "Mean", "Variance", "Nzeros"]
```

```python
print("Descriptivos de 12 de las %d variables numericas:\n" % desc.shape[0])
print(desc.loc[SELECCION,
               ["count", "mean", "std", "min", "max", "asimetria", "curtosis"]].to_string())

# Se guardan las variables mas asimetricas, que son las que mas condicionan la
# eleccion del metodo de deteccion de anomalias.
RES["top_asimetria"] = desc["asimetria"].abs().sort_values(ascending=False).head(6).round(2).to_dict()
```

```
Descriptivos de 12 de las 37 variables numericas:

            count    mean    std    min    max  asimetria  curtosis
LB         2126.0  133.30   9.84  106.0  160.0       0.02     -0.29
AC         2126.0    2.72   3.56    0.0   26.0       1.66      3.12
ASTV       2127.0   47.01  17.21   12.0   87.0      -0.01     -1.05
MSTV       2127.0    1.34   0.89    0.2    7.0       1.72      5.16
ALTV       2127.0    9.88  18.48    0.0   91.0       2.20      4.28
MLTV       2127.0    8.21   5.70    0.0   50.7       1.47      5.20
DS         2128.0    0.00   0.06    0.0    1.0      16.23    261.62
DP         2128.0    0.13   0.47    0.0    4.0       4.29     19.93
Width      2126.0   70.45  38.96    3.0  180.0       0.31     -0.90
Mean       2126.0  134.61  15.59   73.0  182.0      -0.65      0.93
Variance   2126.0   18.81  28.98    0.0  269.0       3.22     15.13
Nzeros     2126.0    0.32   0.71    0.0   10.0       3.92     30.37
```

La tabla admite tres lecturas. La columna **`count`** no es constante: la mayoría de variables tiene 2 126 observaciones válidas y unas pocas 2 127 o 2 128, huella de las filas de resumen detectadas antes.

Las escalas son radicalmente distintas: **`LB`** se mueve en torno a 133 latidos por minuto, **`MSTV`** en torno a 1,3 y **`Variance`** alcanza 269. Cualquier algoritmo basado en la distancia euclídea quedaría dominado por las variables de rango grande, de modo que la estandarización es imprescindible, cuestión que se retoma en la sección 4.

La tercera lectura es la forma de las distribuciones. Variables como **`DS`**, **`DP`**, **`Variance`** o **`Nzeros`** presentan asimetrías muy superiores a 1 y curtosis elevadas, porque son conteos de eventos raros con enorme acumulación de ceros. Esto anticipa que los métodos que asumen normalidad, como el Z-score o la distancia de Mahalanobis, marcarán muchos falsos positivos, y favorece a los no paramétricos.

2.3 Variables categóricas y frecuencias

Listado 7. Celda 2.3. Variables categoricas: categorias y frecuencias. Captura del cuaderno en Google Colab.

```python
# Celda 2.3. Variables categoricas: categorias y frecuencias.
# Objetivo: listar las categorias de cada variable cualitativa y su frecuencia.
#   Se distinguen dos grupos, porque pandas solo reconoce el primero: las
#   categoricas almacenadas como texto (FileName, Date, SegFile) y las
#   codificadas como numeros (CLASS, NSP, Tendency y las diez indicadoras).
#   Tratar estas ultimas como continuas seria un error conceptual, porque la
#   media de NSP no significa nada.

# Categoricas almacenadas como texto
cat_texto = df_bruto.select_dtypes(include=["object"]).columns.tolist()
print("Categoricas de texto (cardinalidad sobre %d filas):" % len(df_bruto))
for col in cat_texto:
    n_cat = df_bruto[col].nunique()
    print("  %-9s %5d categorias distintas  (%.1f %% de las filas)"
          % (col, n_cat, 100 * n_cat / len(df_bruto)))
print("  La cardinalidad casi maxima las identifica como IDENTIFICADORES.")

# Categoricas codificadas como numeros. Tratarlas como continuas seria un error
# conceptual, porque la media de NSP no significa nada.
ETIQUETAS_NSP = {1: "Normal", 2: "Sospechoso", 3: "Patologico"}
frec_nsp = df_bruto["NSP"].value_counts(dropna=False).sort_index()
print("\nFrecuencias de NSP (estado fetal):")
for v, n in frec_nsp.items():
    print("  %-11s %5d   %5.1f %%"
          % (ETIQUETAS_NSP.get(v, "artefacto"), n, 100 * n / frec_nsp.sum()))

frec_class = df_bruto["CLASS"].value_counts().sort_values()
print("\nCLASS   : 10 patrones morfologicos, de %d a %d casos por categoria"
      % (frec_class.iloc[0], frec_class.iloc[-1]))

# Coherencia de la codificacion one-hot de CLASS
COLS_ONEHOT = ["A", "B", "C", "D", "E", "AD", "DE", "LD", "FS", "SUSP"]
suma_onehot = df_bruto[COLS_ONEHOT].sum(axis=1)
print("\nSuma por fila de las 10 indicadoras one-hot:",
      suma_onehot.value_counts(dropna=False).to_dict())
print("Constante e igual a 1: es una recodificacion EXACTA de CLASS, que no")
print("aporta informacion nueva y crea una dependencia lineal perfecta.")

RES["frec_nsp"] = df_bruto["NSP"].value_counts(dropna=False).sort_index().to_dict()
```

```
Categoricas de texto (cardinalidad sobre 2129 filas):
  FileName    352 categorias distintas  (16.5 % de las filas)
  Date         48 categorias distintas  (2.3 % de las filas)
  SegFile    2126 categorias distintas  (99.9 % de las filas)
  La cardinalidad casi maxima las identifica como IDENTIFICADORES.

Frecuencias de NSP (estado fetal):
  Normal       1655    77.7 %
  Sospechoso    295    13.9 %
  Patologico    176     8.3 %
  artefacto       3     0.1 %

CLASS   : 10 patrones morfologicos, de 53 a 579 casos por categoria

Suma por fila de las 10 indicadoras one-hot: {1.0: 2126, 0.0: 3}
Constante e igual a 1: es una recodificacion EXACTA de CLASS, que no
```

```
aporta informacion nueva y crea una dependencia lineal perfecta.
```

El análisis de las categóricas produce cuatro decisiones. **`FileName`**, **`Date`** y **`SegFile`** tienen una cardinalidad casi igual al número de filas, lo que las identifica como identificadores del registro y las descarta. **`NSP`** está muy desbalanceada, con un 77,8 % de normales, un 13,9 % de sospechosos y un 8,3 % de patológicos, y ese desbalance es lo que convierte al conjunto en un buen banco de pruebas para la detección de anomalías. **`CLASS`** reparte los datos en diez categorías con frecuencias de 53 a 579 casos. Y las diez indicadoras de **`A`** a **`SUSP`** suman exactamente 1 en todas las filas, prueba de que son una codificación disyuntiva de **`CLASS`**: mantenerlas duplicaría información y, peor aún, haría singular la matriz de covarianzas, impidiendo calcular la distancia de Mahalanobis.

2.4 Matriz de correlaciones

Listado 8. Celda 2.4. Matriz de correlaciones entre las variables numericas. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 2.4. Matriz de correlaciones entre las variables numericas.
# Objetivo: cuantificar la redundancia lineal entre descriptores. La matriz se
#   calcula solo sobre las 21 variables descriptivas reales, porque incluir los
#   identificadores, las one-hot o las etiquetas produciria correlaciones
#   espurias y una figura ilegible.
# Salidas: la figura fig_correlaciones y la lista de pares muy correlacionados.

# Variables descriptivas: se excluyen identificadores (FileName, Date, SegFile,
# b, e), la redundante LBE, la constante DR, las one-hot y las etiquetas.
VARIABLES = ["LB", "AC", "FM", "UC", "ASTV", "MSTV", "ALTV", "MLTV",
             "DL", "DS", "DP", "Width", "Min", "Max", "Nmax", "Nzeros",
             "Mode", "Mean", "Median", "Variance", "Tendency"]

# Se usan solo las filas validas; las 3 de artefacto se depuran en la seccion 3.
corr = df_bruto[VARIABLES].dropna().corr(method="pearson")

plt.figure(figsize=(9.5, 7.6))
mascara = np.triu(np.ones_like(corr, dtype=bool))   # oculta el triangulo superior
# Se representa el color sin anotar cada coeficiente: con 21 variables son
# 210 numeros que resultarian ilegibles al reducir la figura al ancho de la
# pagina. Los pares fuertes se listan a continuacion en forma de tabla.
sns.heatmap(corr, mask=mascara, annot=False, cmap=CMAP_DIV,
            center=0, vmin=-1, vmax=1, linewidths=0.3,
            cbar_kws={"shrink": 0.8, "label": "r de Pearson"})
plt.title("Matriz de correlaciones de las 21 variables descriptivas")
plt.tight_layout()
guardar("fig_correlaciones")

# Extraccion de los pares fuertemente correlacionados. Se recorre solo el
# triangulo inferior para no repetir cada par dos veces.
pares = []
for i in range(len(VARIABLES)):
    for j in range(i + 1, len(VARIABLES)):
        r = corr.iloc[i, j]
        if abs(r) >= 0.70:
            pares.append((VARIABLES[i], VARIABLES[j], round(float(r), 3)))
[ ]
pares = sorted(pares, key=lambda t: -abs(t[2]))

print("Pares de variables con |r| >= 0.70:\n")
for a, b, r in pares:
    print("  %-9s y %-9s  r = %+.3f" % (a, b, r))

RES["pares_correlacionados"] = pares
RES["corr_media_abs"] = float(np.abs(corr.values[np.triu_indices_from(corr, k=1)]).mean().round(3))
print("\nCorrelacion absoluta media entre pares: %.3f" % RES["corr_media_abs"])
```

```
Pares de variables con |r| >= 0.70:

  Mean      y Median     r = +0.948
  Mode      y Median     r = +0.933
  Width     y Min        r = -0.899
  Mode      y Mean       r = +0.893
  LB        y Median     r = +0.789
  Width     y Nmax       r = +0.747
  LB        y Mean       r = +0.723
  LB        y Mode       r = +0.709

Correlacion absoluta media entre pares: 0.234
```

Figura 1

Matriz de correlaciones de las 21 variables descriptivas

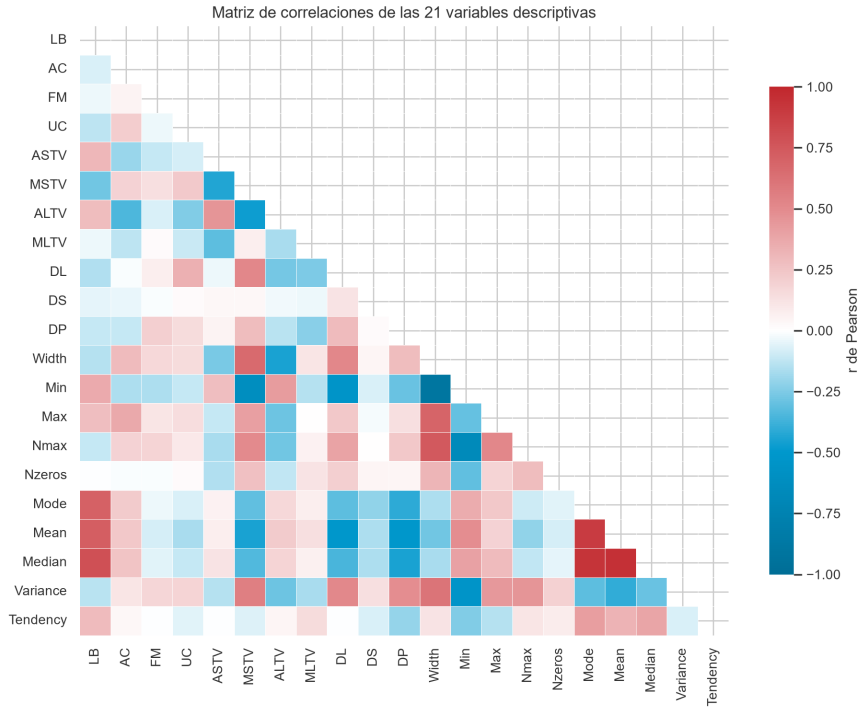

Nota. Coeficientes de correlación de Pearson calculados sobre las 2 126 observaciones válidas. Solo se representa el triángulo inferior para evitar la duplicación de cada par. El valor numérico de los pares más correlacionados aparece en la salida que precede a la figura. Elaboración propia.

La matriz revela una redundancia clara y clínicamente interpretable. Un primer bloque reúne **`Mean`**, **`Median`**, **`Mode`** y **`LB`**, con correlaciones de 0,71 a 0,95, siendo **`Mean`** y **`Median`** el par más redundante: las cuatro miden dónde se sitúa la frecuencia cardiaca y solo cambian de estimador.

Un segundo bloque agrupa los descriptores de dispersión del histograma. **`Width`** correlaciona a −0,90 con **`Min`**, a 0,75 con **`Nmax`** y a 0,69 con **`Max`**. La relación resulta de hecho exacta, porque **`Width`** es igual a **`Max`** menos **`Min`**, como se comprobará en la sección 4; la correlación por pares no llega a revelarla porque la dependencia involucra a tres variables.

También hay correlaciones negativas informativas: **`ASTV`** con **`MSTV`** a −0,43 y **`Variance`** con **`Min`** a −0,55, lo que expresa que cuanto mayor es el tiempo con variabilidad anormal, menor es la variabilidad media efectiva. La redundancia global es moderada, con una correlación absoluta media de 0,234 concentrada en esos dos bloques, de modo que una parte apreciable de la varianza vive en pocas direcciones. Eso justifica recurrir al análisis de componentes principales para visualizar y para mitigar la maldición de la dimensionalidad que sufre DBSCAN.

2.5 Distribuciones de las variables clave

Listado 9. Celda 2.5. Distribucion de las variables mas relevantes. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 2.5. Distribucion de las variables mas relevantes.
# Objetivo: visualizar la forma de la distribucion de un subconjunto
#   representativo de variables, para confirmar graficamente la asimetria que
#   ya se detecto numericamente en la celda 2.2.
# Salidas: las figuras fig_distribuciones y fig_boxplots.

VARS_CLAVE = ["LB", "ASTV", "MSTV", "ALTV", "MLTV", "AC",
              "UC", "DL", "Width", "Variance", "Mean", "Nmax"]

datos_validos = df_bruto[VARIABLES].dropna()

# Histogramas con estimacion de densidad
fig, ejes = plt.subplots(3, 4, figsize=(11, 6.6))
for eje, col in zip(ejes.flatten(), VARS_CLAVE):
    sns.histplot(datos_validos[col], bins=30, kde=True, ax=eje, color=UNIR_CIAN)
    eje.set_title(col + "  (asimetria = %.2f)" % datos_validos[col].skew(), fontsize=10)
    eje.set_xlabel("")
    eje.set_ylabel("")
fig.suptitle("Distribucion de las variables mas relevantes", fontsize=13)
plt.tight_layout()
guardar("fig_distribuciones")

# Diagramas de caja sobre datos estandarizados. Se estandariza solo para poder
# dibujar todas las variables en un mismo eje; el objetivo es comparar la
# CANTIDAD de puntos que quedan fuera de los bigotes.
datos_z = (datos_validos - datos_validos.mean()) / datos_validos.std()

plt.figure(figsize=(10.5, 4.2))
sns.boxplot(data=datos_z, orient="v", fliersize=1.5, color=UNIR_CIAN_CLA)
plt.xticks(rotation=90)
plt.axhline(0, color=UNIR_GRIS, lw=0.8)
plt.ylabel("Valor estandarizado (z)")
plt.title("Diagramas de caja de las 21 variables estandarizadas")
plt.tight_layout()
guardar("fig_boxplots")

[ ]
# Cuantificacion del numero de atipicos univariantes por variable segun la
# regla clasica de Tukey: fuera de [Q1 - 1.5*RIC, Q3 + 1.5*RIC].
q1 = datos_validos.quantile(0.25)
q3 = datos_validos.quantile(0.75)
ric = q3 - q1
atipicos_por_var = ((datos_validos < (q1 - 1.5 * ric)) | (datos_validos > (q3 + 1.5 * ric))).sum()
atipicos_por_var = atipicos_por_var.sort_values(ascending=False)

fuera = ((datos_validos < (q1 - 1.5 * ric)) | (datos_validos > (q3 + 1.5 * ric)))
print("Atipicos univariantes (criterio de Tukey), 8 variables mas afectadas:")
print(atipicos_por_var.head(8).to_string())
print("\nFilas con algun atipico en alguna de las 21 variables: %d de %d (%.1f %%)"
      % (fuera.any(axis=1).sum(), len(datos_validos),
         100 * fuera.any(axis=1).mean()))
RES["atipicos_univariantes"] = atipicos_por_var.head(8).to_dict()

Atipicos univariantes (criterio de Tukey), 8 variables mas afectadas:
Nzeros      502
FM          310
ALTV        309
Variance    184
DP          178
AC           83
DL           81
Mode         73

Filas con algun atipico en alguna de las 21 variables: 1220 de 2126 (57.4 %)
```

Figura 2

Distribución de las variables más relevantes

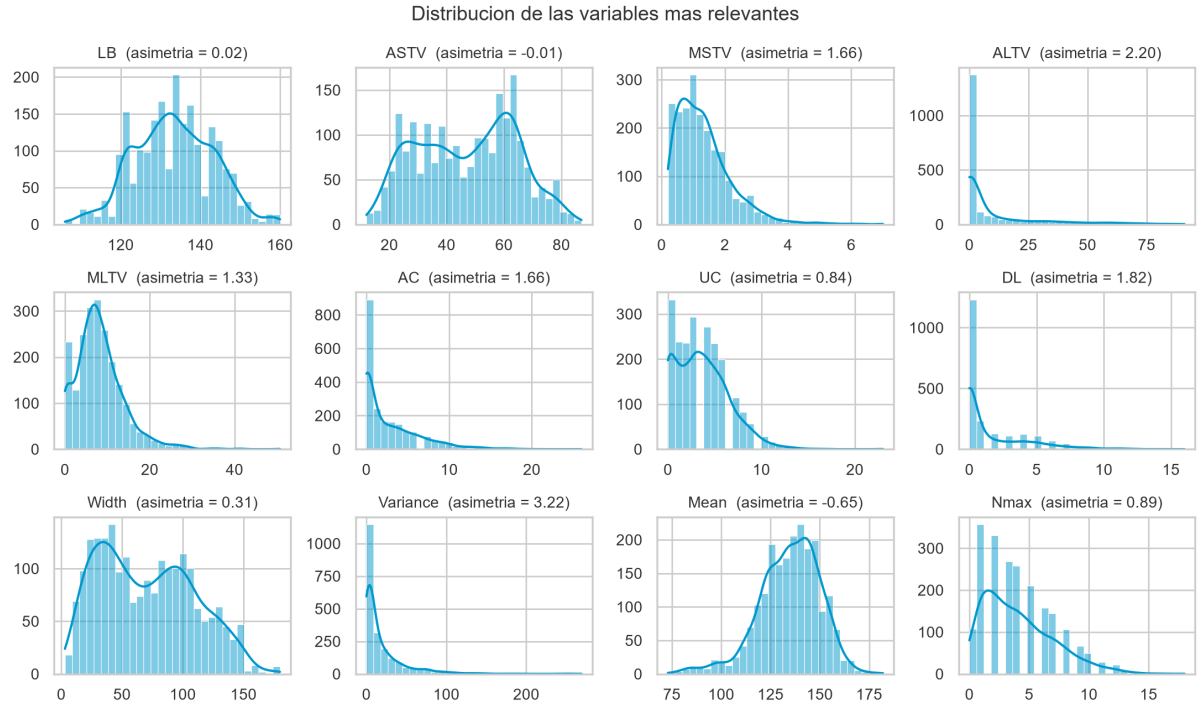

Nota. Histogramas con estimación de densidad por núcleos. Entre paréntesis se indica el coeficiente de asimetría de cada variable. Elaboración propia.

Figura 3

Diagramas de caja de las 21 variables estandarizadas

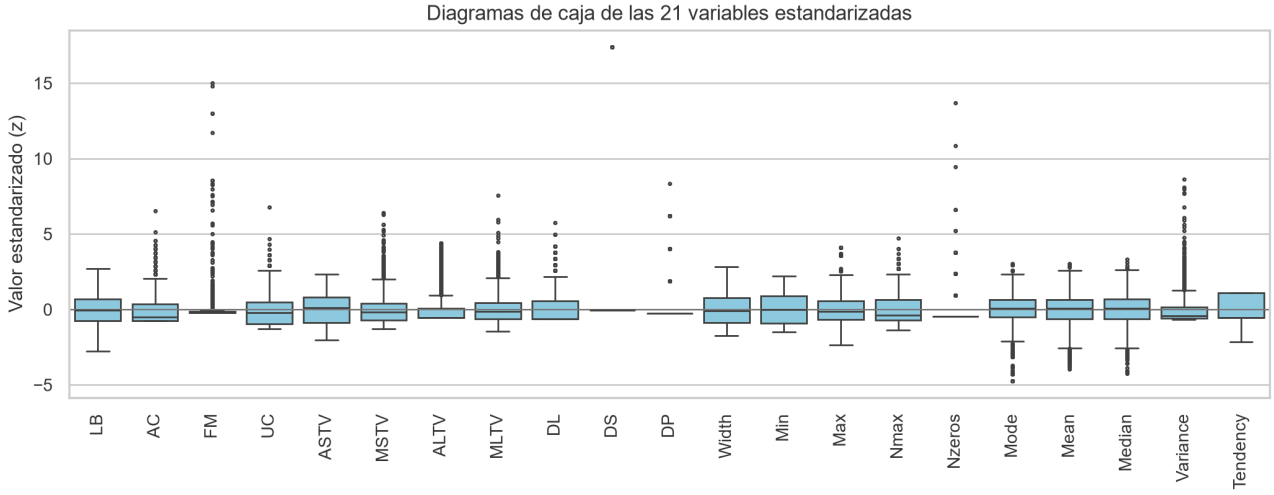

Nota. Las variables se estandarizaron únicamente para poder representarlas en un mismo eje. Los puntos situados fuera de los bigotes son los valores atípicos según el criterio de Tukey. Elaboración propia.

Los histogramas de la figura 2 confirman lo que anticipaban la asimetría y la curtosis: solo **`LB`**, **`Mean`**, **`Mode`** y **`Median`** son aproximadamente simétricas y el resto están fuertemente sesgadas a la derecha, con una masa enorme de ceros en los conteos como **`DS`**, **`DP`** o **`Nzeros`**.

Los diagramas de caja de la figura 3 muestran que casi todas las variables tienen puntos fuera de los bigotes, advertencia metodológica de primer orden: aplicar una regla univariante y eliminar toda fila con algún atípico perdería una fracción enorme del conjunto, y serían justo los casos clínicamente más interesantes los que desaparecerían. La detección de anomalías tiene que ser multivariante.

3. Tratamiento de los valores faltantes

3.1 Diagnóstico

Listado 10. Celda 3.1. Diagnostico de los valores faltantes. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 3.1. Diagnostico de los valores faltantes.
# Objetivo: cuantificar los faltantes y, sobre todo, describir su PATRON. La
#   decision de imputar o eliminar depende del patron y no del recuento:
#   faltantes dispersos y faltantes concentrados en filas completas son
#   problemas distintos que admiten soluciones opuestas.
# Salidas: la serie faltantes y los indices filas_con_na.

faltantes = df_bruto.isnull().sum()

print("Celdas faltantes: %d (%.3f %% del total), en %d de %d columnas"
      % (faltantes.sum(),
         100 * faltantes.sum() / (df_bruto.shape[0] * df_bruto.shape[1]),
         (faltantes > 0).sum(), df_bruto.shape[1]))
print("Faltantes por columna: %s" % faltantes[faltantes > 0].value_counts().to_dict()
      + "  (lectura: n columnas con n faltantes)")

# Analisis del patron: se cuenta cuantos faltantes tiene CADA FILA. La decision
# de imputar o eliminar depende de aquí, no del recuento global.
na_por_fila = df_bruto.isnull().sum(axis=1)
filas_con_na = df_bruto.index[na_por_fila > 0]

print("\nFilas con al menos un faltante: %d  ->  indices %s"
      % (len(filas_con_na), list(filas_con_na)))
print("Faltantes en cada una de esas filas (sobre 40 columnas): %s"
      % na_por_fila[filas_con_na].to_dict())

print("\nContenido de esas tres filas (columnas 8 a 17):")
```

```
print(df_bruto.loc[filas_con_na].iloc[:, 8:18].to_string())

RES["faltantes_total"] = int(faltantes.sum())
RES["filas_con_na"] = [int(i) for i in filas_con_na]
```

```
Celdas faltantes: 106 (0.124 % del total), en 40 de 40 columnas
Faltantes por columna: {3: 30, 2: 6, 1: 4}  (lectura: n columnas con n faltantes)

Filas con al menos un faltante: 3  ->  índices [2126, 2127, 2128]
Faltantes en cada una de esas filas (sobre 40 columnas): {2126: 40, 2127: 36, 2128: 30}

Contenido de esas tres filas (columnas 8 a 17):
          FM    UC  ASTV  MSTV  ALTV  MLTV    DL   DS   DP   DR
2126     NaN   NaN   NaN   NaN   NaN   NaN   NaN  NaN  NaN  NaN
2127     NaN   NaN   NaN   NaN   NaN   NaN   0.0  0.0  0.0  0.0
2128   564.0  23.0  87.0   7.0  91.0  50.7  16.0  1.0  4.0  0.0
```

El diagnóstico es concluyente y desmonta la lectura ingenua del problema. Hay 106 celdas faltantes que afectan a las 40 columnas del archivo, pero todas ellas se concentran en solo 3 filas, las de índice 2126, 2127 y 2128, que son las tres últimas. Esas tres filas no son pacientes con datos incompletos: son las filas de resumen que la hoja de cálculo original dejó al pie de la tabla. La primera está completamente vacía. La segunda contiene ceros en **DL**, **DS**, **DP** y **DR**, que son exactamente los mínimos de esas cuatro columnas. Y la tercera reproduce el máximo de las diez columnas en las que tiene valor, desde **FM** igual a 564 hasta **MLTV** igual a 50,7, coincidencia que se verifica una a una en el apartado siguiente. Ninguna de las tres tiene valor en **NSP** ni en **CLASS**, es decir, ningún obstetra las diagnosticó, sencillamente porque no existen como observaciones.

3.2 Decisión: eliminar frente a imputar

En términos de la tipología de Rubin (1976), este no es un caso de datos faltantes completamente al azar, ni al azar, ni no al azar: no falta ningún dato, sino que hay filas que no son observaciones. La discusión sobre la media, la mediana o la moda solo es pertinente cuando la fila representa a un individuo real del que se desconoce alguna medida.

La decisión es eliminar las tres filas, y la justifican varios argumentos convergentes. Por naturaleza del dato, eliminar no descarta información clínica mientras que imputar fabricaría tres pacientes ficticios. Por coste, se pierden 3 filas de 2 129, apenas el 0,14 %. Y sobre todo por su efecto en los modelos: la fila de máximos, imputada, sería un registro sintético que alcanza a la vez el valor extremo de diez variables distintas, combinación que no se da en ningún trazado real, lo que la convertiría en el atípico multivariante más señalado del conjunto y desplazaría los centroides de K-Means, que no son robustos. Se añade un argumento de trazabilidad: imputar enmascararía un error de origen que conviene dejar documentado.

Imputar con la media sería además internamente incoherente, porque se usaría la media de una columna que la propia fila de resumen ha contaminado para completar esa misma fila.

De ahí una regla general: antes de elegir una estrategia de imputación hay que preguntarse si la fila representa a una entidad real, y solo entonces tiene sentido comparar la media, la mediana, la moda o el vecino más cercano.

Listado 11. Celda 3.2. Aplicacion de la decision: depuracion del conjunto. Captura del cuaderno en Google Colab.

```python
# Celda 3.2. Aplicacion de la decision: depuracion del conjunto.
# Objetivo: eliminar las filas de artefacto y verificar que el conjunto
#   resultante queda completo y es coherente.
# Salidas: df, el DataFrame depurado que se usa en el resto del trabajo.

n_antes = len(df_bruto)

# Criterio de eliminacion: una fila sin diagnostico NSP no es una observacion
# clinica. Es un criterio semantico, basado en el significado de la variable, y
# resulta mas seguro que un dropna() global, que dependeria del azar de cada
# columna.
df = df_bruto.dropna(subset=["NSP"]).reset_index(drop=True)

print("Filas antes de la depuracion  :", n_antes)
print("Filas despues de la depuracion:", len(df))
print("Filas eliminadas              :", n_antes - len(df),
      "(%.2f %% del conjunto)" % (100 * (n_antes - len(df)) / n_antes))

# El conjunto debe quedar sin ningun faltante.
faltantes_despues = df.isnull().sum().sum()
print("\nValores faltantes tras la depuracion:", int(faltantes_despues))
assert faltantes_despues == 0, "Quedan faltantes: revisar el criterio de depuracion"
print("Verificacion superada: el conjunto esta completo.")

# Verificacion de que las filas eliminadas eran filas de resumen y no
# observaciones clinicas: la ultima reproduce el MAXIMO de cada columna en la
# que tiene valor, y la penultima, el MINIMO. Esta comprobacion demuestra su
# naturaleza y explica ademas por que los maximos del conjunto no cambian al
# eliminarlas: la fila de resumen los copiaba de registros reales.
COLS_RESUMEN = ["FM", "UC", "ASTV", "MSTV", "ALTV", "MLTV", "DL", "DS", "DP", "DR"]
iguales_max = int((df_bruto.loc[2128, COLS_RESUMEN].values
                   == df[COLS_RESUMEN].max().values).sum())
iguales_min = int((df_bruto.loc[2127, ["DL", "DS", "DP", "DR"]].values
                   == df[["DL", "DS", "DP", "DR"]].min().values).sum())
print("\nNaturaleza de las filas eliminadas:")
print("  la fila 2128 coincide con el MAXIMO de su columna en %d de %d variables"
      % (iguales_max, len(COLS_RESUMEN)))
print("  la fila 2127 coincide con el MINIMO de su columna en %d de 4 variables"
      % iguales_min)

RES["n_filas_final"] = int(len(df))
RES["n_filas_eliminadas"] = int(n_antes - len(df))
```

```
Filas antes de la depuracion  : 2129
Filas despues de la depuracion: 2126
Filas eliminadas              : 3 (0.14 % del conjunto)

Valores faltantes tras la depuracion: 0
Verificacion superada: el conjunto esta completo.

Naturaleza de las filas eliminadas:
  la fila 2128 coincide con el MAXIMO de su columna en 10 de 10 variables
  la fila 2127 coincide con el MINIMO de su columna en 4 de 4 variables
```

3.3 Experimento de validación

Para respaldar la decisión de forma cuantitativa, y para responder por completo a la pregunta del enunciado sobre la media, la mediana y la moda, se diseña un experimento controlado: se parte del conjunto ya depurado, se borra el 10 % de los valores de forma completamente aleatoria, se reconstruye con media, mediana, moda y vecinos más cercanos con k igual a 5, y se mide el error frente al valor verdadero, que aquí sí se conoce. Así se comparan las estrategias contra una verdad de referencia, algo imposible cuando los faltantes son reales.

Listado 12. Celda 3.3. Experimento controlado de imputacion. Captura del cuaderno en Google Colab.

```python
# Celda 3.3. Experimento controlado de imputacion.
# Objetivo: comparar media, mediana, moda y KNN sobre faltantes SIMULADOS, donde
#   el valor verdadero se conoce y el error puede medirse.
# Metricas: RMSE normalizado, que mide el error de reconstruccion y conviene que
#   sea bajo, y el ratio de desviaciones tipicas, que mide la conservacion de la
#   dispersion y cuyo valor ideal es 1.
# Salidas: el DataFrame comparacion_imp y la figura fig_imputacion.

# Paso 1: matriz completa de referencia
X_completa = df[VARIABLES].copy()

# Paso 2: borrado aleatorio del 10 % de las celdas
generador = np.random.default_rng(SEMILLA)
mascara_na = generador.random(X_completa.shape) < 0.10
X_perforada = X_completa.mask(mascara_na)

print("Celdas borradas artificialmente:", int(mascara_na.sum()),
      "(%.1f %% de la matriz)" % (100 * mascara_na.mean()))

# Paso 3: reconstruccion con cuatro estrategias
ESTRATEGIAS = {
    "Media":    SimpleImputer(strategy="mean"),
    "Mediana":  SimpleImputer(strategy="median"),
    "Moda":     SimpleImputer(strategy="most_frequent"),
    "KNN (k=5)": KNNImputer(n_neighbors=5),
}
```

```python
# Escala de referencia para normalizar el error: la desviacion tipica real de
# cada variable. Sin ella el RMSE quedaria dominado por Variance y Width.
sigma = X_completa.std().replace(0, np.nan)

filas_resultado = []
imputaciones = {}

for nombre, imputador in ESTRATEGIAS.items():
    # fit_transform aprende el estadistico de cada columna y rellena los huecos.
    X_rec = pd.DataFrame(imputador.fit_transform(X_perforada),
                         columns=VARIABLES, index=X_completa.index)
    imputaciones[nombre] = X_rec

    # El error se mide solo en las celdas borradas; las demas son exactas.
    error = (X_rec - X_completa)[mascara_na]
    rmse_norm = float(np.sqrt(((error / sigma) ** 2).stack().mean()))

    # Conservacion de la dispersion: toda imputacion por una constante central
    # reduce artificialmente la varianza de la variable.
    ratio_sd = float((X_rec.std() / X_completa.std()).mean())

    # Conservacion de la estructura de correlaciones, importante para el PCA.
    corr_real = X_completa.corr().values[np.triu_indices(len(VARIABLES), k=1)]
    corr_rec = X_rec.corr().values[np.triu_indices(len(VARIABLES), k=1)]
    error_corr = float(np.abs(corr_real - corr_rec).mean())

    filas_resultado.append({
        "Estrategia": nombre,
        "RMSE normalizado": round(rmse_norm, 4),
        "Ratio desv. tipica": round(ratio_sd, 4),
        "Error medio de correlacion": round(error_corr, 4),
    })

comparacion_imp = pd.DataFrame(filas_resultado).set_index("Estrategia")
print("\nComparacion de estrategias de imputacion (faltantes simulados al 10 %):\n")
print(comparacion_imp.to_string())

RES["comparacion_imputacion"] = comparacion_imp.reset_index().to_dict("records")
```

```
Celdas borradas artificialmente: 4420 (9.9 % de la matriz)

Comparacion de estrategias de imputacion (faltantes simulados al 10 %):

             RMSE normalizado  Ratio desv. tipica  Error medio de correlacion
Estrategia
Media                  0.3815              0.9491                     0.0266
Mediana                0.3986              0.9530                     0.0280
Moda                   0.4814              0.9749                     0.0378
KNN (k=5)              0.2242              0.9834                     0.0064
```

Listado 13. Celda 3.4. Efecto visual de la imputacion sobre las distribuciones. Captura del cuaderno en Google Colab.

```python
# Celda 3.4. Efecto visual de la imputacion sobre las distribuciones.
# Objetivo: mostrar graficamente la distorsion que introduce cada estrategia. La
#   comparacion se hace sobre cuatro variables de forma distinta: una simetrica,
#   una sesgada, una porcentual y una de conteo.
# Salidas: la figura fig_imputacion.

def comparar_distribuciones(df_real, dict_imputados, columnas, ncols=4):
    """Superpone la distribucion real y la imputada para cada variable.

    Parametros
    ----------
    df_real : DataFrame
        Datos completos originales, que hacen de verdad de referencia.
    dict_imputados : dict
        Diccionario {nombre_estrategia: DataFrame imputado}.
    columnas : list
        Variables a representar.
    ncols : int
        Numero de columnas de la rejilla de subgraficos.
    """
    nrows = int(np.ceil(len(columnas) / ncols))
    fig, ejes = plt.subplots(nrows, ncols, figsize=(ncols * 2.9, nrows * 2.7))
    ejes = np.atleast_1d(ejes).flatten()

    for eje, col in zip(ejes, columnas):
        # Distribucion verdadera como referencia, con area rellena.
        sns.kdeplot(df_real[col], ax=eje, color=UNIR_GRIS_OSC, lw=2,
                    label="Original", fill=True, alpha=0.12)
        # Una curva por estrategia de imputacion.
        for nombre, X_rec in dict_imputados.items():
            sns.kdeplot(X_rec[col], ax=eje, lw=1.3, label=nombre)
        eje.set_title(col, fontsize=10)
        eje.set_xlabel("")
        eje.set_ylabel("")
        eje.legend(fontsize=8)

    # Se eliminan los ejes sobrantes de la rejilla.
    for eje in ejes[len(columnas):]:
        fig.delaxes(eje)

    fig.suptitle("Efecto de cada estrategia de imputacion sobre la distribucion",
                 fontsize=12)
    plt.tight_layout()


comparar_distribuciones(X_completa, imputaciones,
                        ["LB", "ASTV", "MSTV", "Variance"])
guardar("fig_imputacion")
```

Figura 4

Efecto de cada estrategia de imputación sobre la distribución

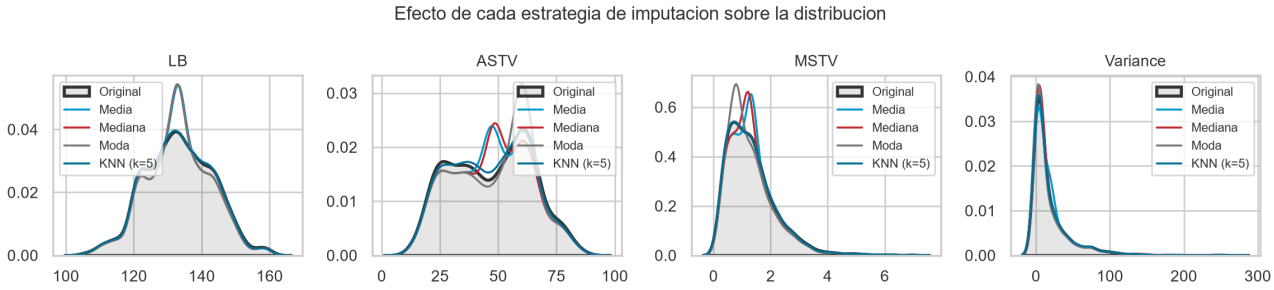

Nota. Curvas de densidad obtenidas tras borrar de forma aleatoria el 10 % de los valores y reconstruirlos con cuatro estrategias distintas. El área sombreada corresponde a la distribución original. Elaboración propia.

El experimento cuantifica lo que la teoría anticipaba. La imputación por vecinos más cercanos gana en las tres métricas: su RMSE normalizado es de 0,224 frente a 0,382 de la media, 0,399 de la mediana y 0,481 de la moda, casi la mitad de error. La razón es que estima cada hueco a partir de las cinco observaciones más parecidas y aprovecha la correlación documentada en el apartado 2.4, estructura que los imputadores por constante ignoran.

Todas comprimen la dispersión, con el ratio de desviaciones típicas por debajo de 1: sustituir el 10 % de los valores por un número central reduce la varianza de forma mecánica. La media es la que más la degrada, con 0,949, y el método de vecinos la que menos, con 0,983. Este último es además el único que preserva la estructura de correlaciones, decisivo para el análisis de componentes principales posterior: su error medio en la matriz es de 0,006, cuatro veces menor que el de la media y seis veces menor que el de la moda.

La figura 4 muestra un aspecto que el RMSE no captura. La media, en cian claro, y la mediana, en rojo, crean un pico artificial en el valor central de **`ASTV`** y de **`MSTV`** que no existe en la distribución real. La moda, en gris, deforma el pico de **`LB`** y de **`MSTV`** al concentrar masa en el valor más frecuente. La curva de vecinos, en cian oscuro, se superpone casi exactamente al área sombreada de la distribución original.

Si en este conjunto hubiera habido faltantes reales y dispersos, la elección correcta habría sido la imputación por vecinos más cercanos, y por un margen amplio. La media y la mediana quedan muy igualadas, porque la primera reconstruye algo mejor y la segunda conserva algo mejor la dispersión, mientras que la moda debe descartarse para variables continuas. Pero como los faltantes proceden de tres filas que no son observaciones, se aplica la eliminación y el conjunto de trabajo queda con 2 126 registros completos.

4. Preparación de la matriz de características

Decidir con qué columnas se alimenta a los algoritmos es la decisión de mayor impacto del trabajo, y se toma con las evidencias del análisis exploratorio.

Se descartan **`FileName`**, **`Date`**, **`SegFile`**, **`b`** y **`e`** porque identifican el registro y no describen al feto; **`LBE`** por duplicar exactamente a **`LB`**; **`DR`** por ser constante e igual a cero, con varianza nula; **`Width`** por ser combinación lineal exacta de otras dos columnas; y las diez indicadoras de **`A`** a **`SUSP`** por

ser la codificación disyuntiva de **`CLASS`**. Se apartan **`CLASS`** y **`NSP`** como verdad de referencia externa. Las veinte columnas restantes son descriptores genuinos del trazado y forman la matriz de trabajo.

4.1 Por qué importa eliminar la variable Width

La igualdad entre **`Width`** y la diferencia de **`Max`** y **`Min`** se cumple en las 2 126 filas sin excepción, lo que deja la matriz con rango 20 sobre 21 columnas: su matriz de covarianzas es singular y no puede invertirse. La distancia de Mahalanobis exige esa inversión, de modo que mantener **`Width`** haría fracasar uno de los cinco detectores de la sección 5. Es un ejemplo de por qué el análisis exploratorio debe preceder al modelado.

4.2 Por qué estandarizar

K-Means, DBSCAN, el factor local de atipicidad y la distancia de Mahalanobis se basan en distancias. Con las escalas originales **`Variance`**, de 0 a 269, pesaría cientos de veces más que **`MSTV`**, entre 0 y 7, solo por su unidad de medida. La estandarización resta a cada valor la media de su columna y lo divide entre la desviación típica, dejando todas las variables con media cero y desviación uno, de manera que cada descriptor contribuye en igualdad de condiciones.

Listado 14. Celda 4.1. Construccion de la matriz de caracteristicas. Captura del cuaderno en Google Colab.

```python
# Celda 4.1. Construccion de la matriz de caracteristicas.
# Objetivo: materializar las decisiones descritas arriba y verificar
#   numericamente que se resuelven los problemas detectados.
# Salidas: X, la matriz sin escalar; Z, la matriz estandarizada; y las etiquetas
#   y_nsp e y_class, apartadas para la validacion externa.

# Verificacion previa de las redundancias detectadas en el EDA.
print("Comprobaciones de redundancia:")
print("  LBE identica a LB          :", bool((df["LBE"] == df["LB"]).all()))
print("  DR constante               :", df["DR"].nunique() == 1,
      "(valores unicos:", df["DR"].unique().tolist(), ")")
print("  Width == Max - Min         :", bool((df["Width"] == (df["Max"] - df["Min"])).all()))

# Conjunto final de variables
VARIABLES_MODELO = ["LB", "AC", "FM", "UC", "ASTV", "MSTV", "ALTV", "MLTV",
                    "DL", "DS", "DP", "Min", "Max", "Nmax", "Nzeros",
                    "Mode", "Mean", "Median", "Variance", "Tendency"]

X = df[VARIABLES_MODELO].copy()          # matriz en unidades originales
y_nsp = df["NSP"].astype(int).values     # etiqueta apartada (3 niveles)
y_class = df["CLASS"].astype(int).values # etiqueta apartada (10 patrones)

print("\nMatriz de caracteristicas:", X.shape[0], "observaciones x",
      X.shape[1], "variables")

# Estandarizacion: StandardScaler calcula mu y sigma por columna y aplica
# z = (x - mu) / sigma.
escalador = StandardScaler()
Z = escalador.fit_transform(X)

print("\nEfecto de la estandarizacion (3 variables de control):")
print("  %-10s %12s %12s | %10s %10s" % ("Variable", "media orig.", "desv. orig.",
                                          "media z", "desv. z"))
for v in ["LB", "MSTV", "Variance"]:
    k = VARIABLES_MODELO.index(v)
    print("  %-10s %12.2f %12.2f | %10.2f %10.2f"
          % (v, X[v].mean(), X[v].std(), Z[:, k].mean(), Z[:, k].std()))

# La matriz debe tener rango completo para que su covarianza sea invertible.
rango = np.linalg.matrix_rank(Z)
print("\nRango de la matriz estandarizada:", rango, "de", Z.shape[1], "columnas")
assert rango == Z.shape[1], "La matriz sigue siendo singular: revisar redundancias"
print("Verificacion superada: la covarianza es invertible.")

RES["n_variables_modelo"] = len(VARIABLES_MODELO)
RES["variables_modelo"] = VARIABLES_MODELO
```

```
Comprobaciones de redundancia:
  LBE identica a LB          : True
  DR constante               : True (valores unicos: [0.0] )
  Width == Max - Min         : True

Matriz de caracteristicas: 2126 observaciones x 20 variables

Efecto de la estandarizacion (3 variables de control):
  Variable    media orig.  desv. orig. |    media z    desv. z
  LB               133.30         9.84 |       0.00       1.00
  MSTV               1.33         0.88 |       0.00       1.00
  Variance          18.81        28.98 |      -0.00       1.00

Rango de la matriz estandarizada: 20 de 20 columnas
Verificacion superada: la covarianza es invertible.
```

Listado 15. Celda 4.2. Analisis de componentes principales. Captura del cuaderno en Google Colab.

```python
# Celda 4.2. Analisis de componentes principales.
# Objetivo: cuantificar la dimensionalidad efectiva del problema y obtener una
#   proyeccion en dos dimensiones que se reutilizara para visualizar tanto las
#   anomalias de la seccion 5 como los grupos de la seccion 6.
# Nota: el PCA se ajusta sobre datos ya estandarizados, lo que equivale a
#   diagonalizar la matriz de correlaciones y no la de covarianzas.
# Salidas: el objeto pca, la matriz Z_pca con todas las componentes y Z2 con las
#   dos primeras.

pca = PCA(random_state=SEMILLA)
Z_pca = pca.fit_transform(Z)

varianza = pca.explained_variance_ratio_
acumulada = np.cumsum(varianza)

print("Varianza explicada por las primeras componentes principales:")
print("  CP    individual    acumulada")
for i in range(6):
    print("  %2d    %8.1f %%   %8.1f %%" % (i + 1, 100 * varianza[i], 100 * acumulada[i]))

# Componentes necesarias para retener el 80 % y el 90 % de la varianza.
n80 = int(np.searchsorted(acumulada, 0.80) + 1)
n90 = int(np.searchsorted(acumulada, 0.90) + 1)
print("  Componentes necesarias: %d para el 80 %% de la varianza y %d para el 90 %%"
      % (n80, n90))

# Grafico de sedimentacion y varianza acumulada
fig, (a1, a2) = plt.subplots(1, 2, figsize=(10, 3.5))

a1.bar(range(1, len(varianza) + 1), 100 * varianza, color=UNIR_CIAN)
a1.set_xlabel("Componente principal")
a1.set_ylabel("Varianza explicada (%)")
a1.set_title("Grafico de sedimentacion")

a2.plot(range(1, len(acumulada) + 1), 100 * acumulada, "o-", color=UNIR_CIAN_OSC)
a2.axhline(80, ls="--", color=UNIR_GRIS, lw=1)
a2.axhline(90, ls=":", color=UNIR_GRIS, lw=1)
a2.set_xlabel("Numero de componentes")
a2.set_ylabel("Varianza acumulada (%)")
a2.set_title("Varianza acumulada")
plt.tight_layout()
guardar("fig_pca_varianza")

# Las cargas indican con que peso entra cada variable original en cada
# componente, y son la clave para interpretarlas.
cargas = pd.DataFrame(pca.components_[:2].T, index=VARIABLES_MODELO,
                      columns=["CP1", "CP2"]).round(3)
def resumen_cargas(cp, n=4):
    """Devuelve, en una sola linea, las n cargas mas negativas y las n mas positivas."""
    orden = cargas[cp].sort_values()
    extremos = list(orden.head(n).items()) + list(orden.tail(n).items())
    return ", ".join("%s %+.2f" % (v, x) for v, x in extremos)


print("\nCargas extremas de CP1:", resumen_cargas("CP1"))
print("Cargas extremas de CP2:", resumen_cargas("CP2"))

Z2 = Z_pca[:, :2]            # proyeccion 2D reutilizada en todas las figuras
Z_pca80 = Z_pca[:, :n80]     # espacio reducido al 80 % de varianza

RES["pca_var"] = [round(float(v), 4) for v in varianza[:8]]
RES["pca_n80"] = n80
```

```
Varianza explicada por las primeras componentes principales:
  CP    individual    acumulada
   1       27.5 %       27.5 %
   2       15.8 %       43.3 %
   3        9.1 %       52.4 %
   4        7.3 %       59.8 %
   5        5.8 %       65.6 %
   6        5.2 %       70.8 %
  Componentes necesarias: 9 para el 80 % de la varianza y 12 para el 90 %

Cargas extremas de CP1: MSTV -0.31, Variance -0.28, DL -0.28, DP -0.23, Mode +0.32, Min +0.32, Median +0.33, Mean +0.36
Cargas extremas de CP2: ALTV -0.20, Min -0.20, ASTV -0.16, DS -0.07, Nmax +0.30, Mode +0.33, Median +0.33, Max +0.42
```

Figura 5

Sedimentación y varianza acumulada del análisis de componentes principales

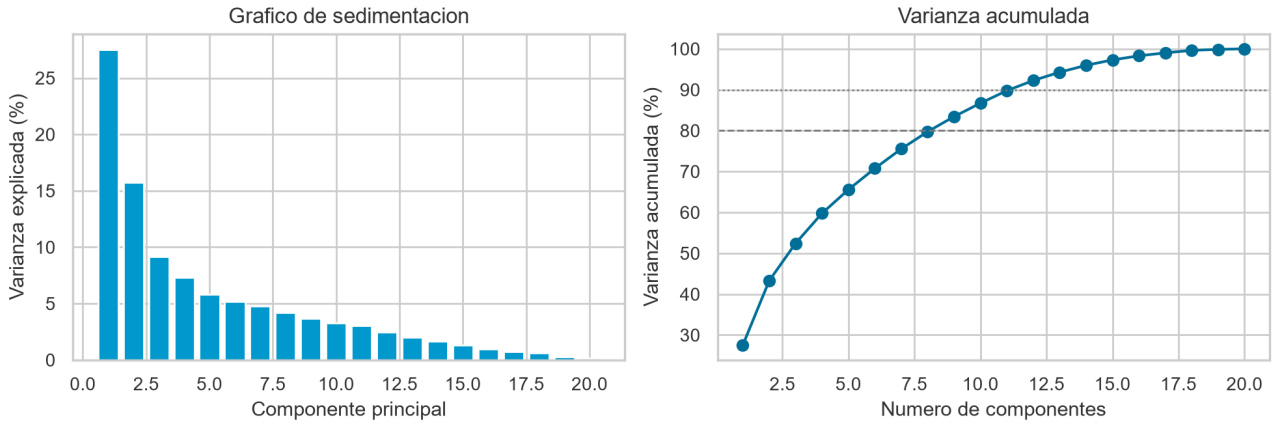

Nota. Las líneas discontinuas señalan los umbrales del 80 % y del 90 % de varianza explicada. Elaboración propia.

La primera componente explica el 27,5 % de la varianza y la segunda el 15,8 %, de modo que entre ambas apenas superan el 43 % y hacen falta nueve para alcanzar el 80 %. El problema no es de dimensionalidad trivial: no puede resumirse en dos ejes sin perder información sustancial,

así que las dos primeras componentes se usarán solo para visualizar.

Las cargas admiten lectura clínica directa. La primera componente contrapone las variables de tendencia central y anchura del histograma, **`Mean`**, **`Mode`**, **`Median`** y **`Max`**, frente a las de variabilidad anormal, **`ASTV`** y **`ALTV`**. La segunda separa la actividad del registro, medida por **`AC`**, **`FM`** y **`UC`**, de las deceleraciones. Son los dos ejes con los que un obstetra describiría un trazado.

5. Detección de anomalías

5.1 Planteamiento

Una anomalía es una observación que se aparta del comportamiento mayoritario del conjunto. La pregunta operativa aquí es si se pueden señalar automáticamente los trazados inusuales sin recurrir al diagnóstico del obstetra.

Se aplican cinco técnicas de tres familias. El Z-score y la regla de Tukey son univariantes: el primero marca una observación cuando algún valor tipificado supera 3 en valor absoluto, y asume normalidad; la segunda la marca cuando algún valor cae fuera del intervalo entre el primer cuartil menos vez y media el rango intercuartílico y el tercer cuartil más esa cantidad, sin asumir distribución alguna pero examinando las variables de una en una. La distancia de Mahalanobis con estimación robusta de la covarianza es multivariante, mide la separación al centro ponderándola por la correlación y presupone normalidad multivariante. Isolation Forest es un ensamble de árboles apoyado en que los puntos raros se aíslan con pocos cortes aleatorios. Y el factor local de atipicidad, LOF, compara la densidad de cada punto con la de sus vecinos; ninguno de los dos últimos impone supuestos distribucionales.

Para que la comparación sea justa, los métodos multivariantes se calibran al mismo 5 % de observaciones marcadas. La evaluación no se limita a contar: se recurre a **`NSP`**, que ningún modelo ha visto, para medir el enriquecimiento en casos patológicos, magnitud conocida como lift y definida como el cociente entre la probabilidad de que una observación sea patológica dado que el detector la ha marcado y la probabilidad de que lo sea sin más información. Un lift de 1 significa que el detector no aporta nada frente al azar.

5.2 Métodos univariantes de referencia

Listado 16. Celda 5.1. Metodos univariantes: Z-score y regla de Tukey. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 5.1. Metodos univariantes: Z-score y regla de Tukey.
# Objetivo: establecer una linea base con las dos reglas clasicas. Se aplican
#   variable a variable y se marca la fila cuando alguna de sus 20 variables
#   resulta atipica.
# Salidas: las mascaras booleanas anom_zscore y anom_iqr.

# Z-score: se marca cuando |x - mu| / sigma supera 3. Bajo normalidad, ese
# umbral deja fuera solo el 0,27 % de los casos por variable.
puntuaciones_z = np.abs((X - X.mean()) / X.std())
anom_zscore = (puntuaciones_z > 3).any(axis=1).values

# Regla de Tukey: fuera de [Q1 - 1.5*RIC, Q3 + 1.5*RIC].
Q1 = X.quantile(0.25)
Q3 = X.quantile(0.75)
RIC = Q3 - Q1
limite_inf = Q1 - 1.5 * RIC
limite_sup = Q3 + 1.5 * RIC
anom_iqr = ((X < limite_inf) | (X > limite_sup)).any(axis=1).values

print("METODOS UNIVARIANTES DE REFERENCIA\n")
print("Z-score (|z| > 3)      : %4d filas marcadas (%.1f %% del conjunto)"
      % (anom_zscore.sum(), 100 * anom_zscore.mean()))
print("Tukey (1.5 x RIC)      : %4d filas marcadas (%.1f %% del conjunto)"
      % (anom_iqr.sum(), 100 * anom_iqr.mean()))

# El problema de fondo es que la probabilidad de falso positivo se acumula con
# el numero de variables analizadas simultaneamente.
```

```python
p_falso_positivo = 1 - (1 - 0.0027) ** len(VARIABLES_MODELO)
print("\nProbabilidad teorica de que una fila NORMAL sea marcada por el Z-score")
print("al examinar %d variables independientes: %.1f %%"
      % (len(VARIABLES_MODELO), 100 * p_falso_positivo))

RES["n_zscore"] = int(anom_zscore.sum())
RES["n_iqr"] = int(anom_iqr.sum())
```

```
METODOS UNIVARIANTES DE REFERENCIA

Z-score (|z| > 3)      :  343 filas marcadas (16.1 % del conjunto)
Tukey (1.5 x RIC)      : 1220 filas marcadas (57.4 % del conjunto)

Probabilidad teorica de que una fila NORMAL sea marcada por el Z-score
al examinar 20 variables independientes: 5.3 %
```

Las reglas univariantes fracasan. El Z-score marca 343 filas, el 16,1 % del total, más de tres veces la contaminación razonable. La regla de Tukey marca 1 220 filas, el 57,4 %: un detector que declara anómala a más de la mitad de la población no detecta nada.

La causa es doble. Por un lado, las comparaciones múltiples: aun suponiendo normalidad e independencia, examinar 20 variables con umbral de 3 desviaciones típicas eleva la probabilidad acumulada de falso positivo al 5,3 % por fila. Por otro, y más importante, las variables no son normales, y con asimetrías extremas y exceso de ceros el rango intercuartílico se vuelve minúsculo, de modo que casi cualquier valor no nulo cae fuera de los bigotes.

La anormalidad de un trazado no reside en ninguna variable aislada sino en la combinación de sus valores, y capturarla exige métodos multivariantes.

5.3 Distancia de Mahalanobis robusta

Listado 17. Celda 5.2. Distancia de Mahalanobis con estimacion robusta de la covarianza. Captura del cuaderno en Google Colab.

```python
# Celda 5.2. Distancia de Mahalanobis con estimacion robusta de la covarianza.
# Objetivo: primer metodo multivariante. La distancia de Mahalanobis mide la
#   separacion al centro de la nube teniendo en cuenta la correlacion, mediante
#   d^2(x) = (x - mu)^T S^-1 (x - mu). Se usa el estimador MCD, que busca el
#   subconjunto mas compacto de los datos, en lugar de la media y la covarianza
#   muestrales, porque estas son ellas mismas sensibles a los atipicos y
#   producen el llamado efecto de enmascaramiento.
# Salidas: dist_mahalanobis y la mascara anom_mahalanobis.

# support_fraction = 0.85 indica que el MCD busca el subconjunto del 85 % de los
# datos cuya covarianza tiene el menor determinante, es decir, el nucleo denso.
mcd = MinCovDet(support_fraction=0.85, random_state=SEMILLA).fit(Z)
dist_mahalanobis = mcd.mahalanobis(Z)     # devuelve d^2, no d

# Criterio A: umbral teorico chi-cuadrado. Bajo normalidad multivariante, d^2
# sigue una distribucion chi2 con p grados de libertad.
umbral_chi2 = stats.chi2.ppf(0.975, df=len(VARIABLES_MODELO))
marcados_chi2 = dist_mahalanobis > umbral_chi2

# Criterio B: proporcion fija del 5 %, para poder comparar con los demas.
N_ANOMALIAS = int(round(0.05 * len(Z)))
umbral_5pct = np.sort(dist_mahalanobis)[-N_ANOMALIAS]
anom_mahalanobis = dist_mahalanobis >= umbral_5pct

print("Umbral teorico chi2(0.975, %d gl) = %.1f" % (len(VARIABLES_MODELO), umbral_chi2))
print("  marcaria %d filas (%.1f %% del conjunto)"
      % (marcados_chi2.sum(), 100 * marcados_chi2.mean()))
print("\nUmbral empirico al 5 %% (d^2 >= %.1f)" % umbral_5pct)
print("  marca %d filas (%.1f %% del conjunto)"
      % (anom_mahalanobis.sum(), 100 * anom_mahalanobis.mean()))

# Contraste del supuesto de normalidad multivariante. Si se cumpliera, los
# cuantiles empiricos de d^2 coincidirian con los de la chi2.
cuantiles_teoricos = stats.chi2.ppf(
    (np.arange(len(Z)) + 0.5) / len(Z), df=len(VARIABLES_MODELO))

plt.figure(figsize=(10, 3.8))
plt.subplot(1, 2, 1)
plt.plot(cuantiles_teoricos, np.sort(dist_mahalanobis), ".", ms=2.5, color=UNIR_CIAN)
lim = max(cuantiles_teoricos.max(), 120)
plt.plot([0, lim], [0, lim], "--", color=UNIR_ROJO, lw=1, label="Ajuste perfecto a chi2")
plt.xlim(0, lim); plt.ylim(0, np.percentile(dist_mahalanobis, 99.5))
plt.xlabel("Cuantiles teoricos chi2"); plt.ylabel("Distancia de Mahalanobis al cuadrado")
plt.title("Grafico Q-Q del supuesto de normalidad multivariante")
plt.legend(fontsize=9)

plt.subplot(1, 2, 2)
plt.hist(dist_mahalanobis, bins=80, color=UNIR_CIAN, range=(0, np.percentile(dist_mahalanobis, 99)))
plt.axvline(umbral_5pct, color=UNIR_ROJO, ls="--", label="Umbral empirico 5 %")
plt.axvline(umbral_chi2, color=UNIR_AMBAR, ls=":", label="Umbral chi2 0.975")
plt.xlabel("Distancia de Mahalanobis al cuadrado"); plt.ylabel("Frecuencia")
plt.title("Distribucion de las distancias")
plt.legend(fontsize=9)
plt.tight_layout()
guardar("fig mahalanobis")

RES["n_mahalanobis_chi2"] = int(marcados_chi2.sum())
```

```
Umbral teorico chi2(0.975, 20 gl) = 34.2
  marcaria 646 filas (30.4 % del conjunto)

Umbral empirico al 5 % (d^2 >= 465.5)
  marca 106 filas (5.0 % del conjunto)
```

Figura 6

Contraste del supuesto de normalidad multivariante

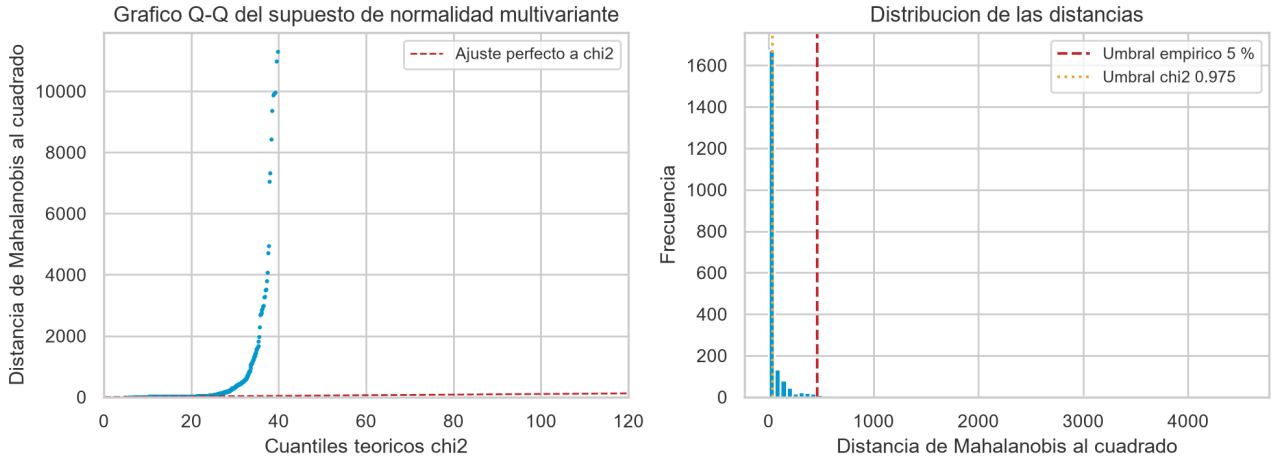

Nota. A la izquierda, gráfico cuantil-cuantil de la distancia de Mahalanobis robusta frente a la distribución chi-cuadrado con 20 grados de libertad. A la derecha, distribución empírica de esas distancias con los dos umbrales considerados. Elaboración propia.

El gráfico cuantil-cuantil se separa pronto de la diagonal: las distancias observadas crecen mucho más rápido que las que predice la chi-cuadrado. El supuesto de normalidad multivariante no se cumple, y por eso el umbral teórico marca 646 observaciones, el 30,4 % del conjunto, cifra sin sentido operativo porque ningún servicio revisaría a mano tres de cada diez registros. Se conserva el umbral empírico del 5 %, que además permite comparar el método con Isolation Forest y con LOF en igualdad de condiciones.

5.4 Isolation Forest

Propuesto por Liu, Ting y Zhou (2008), parte de una observación sencilla: si se particiona el espacio eligiendo al azar una variable y un punto de corte, un punto anómalo queda aislado en muy pocos cortes mientras que uno del núcleo denso necesita muchos. El algoritmo construye un bosque de árboles aleatorios y asigna a cada observación una puntuación según su profundidad media de aislamiento.

A diferencia de casi todos los demás, no modela la normalidad para buscar desviaciones sino que modela directamente la rareza. No asume distribución alguna, tolera la alta dimensionalidad y su coste es lineal.

Listado 18. Celda 5.3. Isolation Forest. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 5.3. Isolation Forest.
# Objetivo: detectar anomalias mediante aislamiento aleatorio recursivo.
# Parametros: n_estimators = 200 fija el numero de arboles, y cuantos mas haya
#   mas estable es la puntuacion; contamination = 0.05 declara la proporcion
#   esperada de anomalias y con ello fija el umbral de decision; max_samples =
#   256 es la submuestra por arbol recomendada por los autores, ya que
#   submuestrear mejora la deteccion al reducir el enmascaramiento entre
#   anomalias proximas.
# Salidas: score_iforest, donde un valor mayor indica mas anomalo, y la mascara
#   anom_iforest.

iforest = IsolationForest(
    n_estimators=200,
    contamination=0.05,
    max_samples=256,
    random_state=SEMILLA,
    n_jobs=-1,
)
# fit_predict devuelve -1 para las anomalias y +1 para las observaciones normales.
etiquetas_if = iforest.fit_predict(Z)
anom_iforest = etiquetas_if == -1

# score_samples devuelve valores negativos y cuanto menor es el valor, mas
# anomala es la observacion. Se invierte el signo para que "mayor" signifique
# "mas anomalo" y la lectura resulte natural.
score_iforest = -iforest.score_samples(Z)
```

```python
print("Isolation Forest: %d arboles, %d observaciones marcadas (%.1f %%), "
      "umbral aprendido %.4f"
      % (iforest.n_estimators, anom_iforest.sum(),
         100 * anom_iforest.mean(), -iforest.offset_))
print("Puntuacion de anormalidad: min %.3f | mediana %.3f | max %.3f"
      % (score_iforest.min(), np.median(score_iforest), score_iforest.max()))

# Para saber QUE hace anomalas a las observaciones marcadas se compara su perfil
# medio, en unidades z, con el del resto del conjunto.
perfil = pd.DataFrame({
    "Media z (anomalias)": Z[anom_iforest].mean(axis=0),
    "Media z (resto)": Z[~anom_iforest].mean(axis=0),
}, index=VARIABLES_MODELO)
perfil["Diferencia"] = (perfil["Media z (anomalias)"] - perfil["Media z (resto)"]).round(2)
perfil = perfil.round(2).reindex(perfil["Diferencia"].abs().sort_values(ascending=False).index)

print("\nPerfil de las anomalias detectadas (en desviaciones tipicas):\n")
print(perfil.head(8).to_string())

RES["perfil_iforest"] = perfil.head(8)["Diferencia"].to_dict()
```

```
Isolation Forest: 200 arboles, 107 observaciones marcadas (5.0 %), umbral aprendido 0.5242
Puntuacion de anormalidad: min 0.365 | mediana 0.420 | max 0.627

Perfil de las anomalias detectadas (en desviaciones tipicas):

           Media z (anomalias)  Media z (resto)  Diferencia
Variance                  2.22            -0.12        2.33
DP                        2.10            -0.11        2.22
MSTV                      1.60            -0.08        1.68
Max                       1.47            -0.08        1.54
Mean                     -1.41             0.07       -1.48
Mode                     -1.32             0.07       -1.39
Nmax                      1.26            -0.07        1.33
DL                        1.25            -0.07        1.32
```

El perfil de las observaciones marcadas es clínicamente coherente y sirve de validación cualitativa. Las ocho variables que más las separan del resto las sitúan muy por encima de la media en **`Variance`**, con 2,33 desviaciones típicas de diferencia, en **`DP`**, las deceleraciones prolongadas, con 2,22, en **`MSTV`**, variabilidad errática a corto plazo, con 1,68, y también en **`Max`**, **`Nmax`** y **`DL`**; y muy por debajo en **`Mean`**, con 1,48 menos, y en **`Mode`**, con 1,39, con el mismo desplazamiento atenuado en **`Median`** y **`Min`**.

En lenguaje clínico, el algoritmo ha aislado trazados con bradicardia, ya que toda la tendencia central aparece desplazada a la baja, acompañada de deceleraciones prolongadas y severas y de variabilidad amplia y errática. Es la descripción de manual de un trazado no tranquilizador, reconstruida sin haber visto un solo diagnóstico.

Un matiz: **`ALTV`** aparece por debajo de la media en las anomalías, con 0,54 desviaciones típicas menos. Isolation Forest no captura el fenotipo del trazado plano, de variabilidad reducida y monótona, sino el errático y decelerativo. Son dos formas distintas de compromiso fetal y el detector se especializa en la segunda.

5.5 Factor local de atipicidad

Propuesto por Breunig y sus colaboradores en 2000, no busca puntos lejanos del centro sino situados en zonas menos densas que su propio vecindario: compara la densidad local de cada observación con la media de sus k vecinos, y un cociente muy superior a 1 indica que el punto está más solo que quienes lo rodean.

Su ventaja es detectar anomalías locales, anómalas respecto de su grupo aunque no sean extremas en el conjunto global. Su debilidad, la dependencia crítica de k y la degradación de la densidad en dimensión alta.

Listado 19. Celda 5.4. Factor local de atipicidad (LOF). Captura del cuaderno en Google Colab.

```
# Celda 5.4. Factor local de atipicidad (LOF).
# Objetivo: detectar anomalias por contraste de densidad local.
# Parametros: n_neighbors = 20 fija el tamano del vecindario, valor por defecto
#   recomendado, ya que un vecindario demasiado pequeno introduce ruido y uno
#   demasiado grande borra el caracter local del metodo; contamination = 0.05
#   mantiene la misma proporcion que Isolation Forest para poder comparar.
# Salidas: score_lof y la mascara anom_lof.

lof = LocalOutlierFactor(n_neighbors=20, contamination=0.05, n_jobs=-1)
etiquetas_lof = lof.fit_predict(Z)
anom_lof = etiquetas_lof == -1

# negative_outlier_factor_ es el LOF con el signo cambiado; se reinvierte.
score_lof = -lof.negative_outlier_factor_

print("Local Outlier Factor")
print("  Tamano del vecindario  :", lof.n_neighbors)
print("  Observaciones marcadas : %d (%.1f %%)" % (anom_lof.sum(), 100 * anom_lof.mean()))
print("  Factor LOF: min = %.2f | mediana = %.2f | max = %.2f"
      % (score_lof.min(), np.median(score_lof), score_lof.max()))

# Sensibilidad al parametro k: se comprueba cuanto cambia el conjunto detectado
# al variar el tamano del vecindario.
print("\nSensibilidad al numero de vecinos (solapamiento con k = 20):")
base_lof = anom_lof
for k in [5, 10, 20, 35, 50]:
    m = LocalOutlierFactor(n_neighbors=k, contamination=0.05).fit_predict(Z) == -1
    jac = (m & base_lof).sum() / (m | base_lof).sum()
    print("  k = %2d: %3d marcadas, indice de Jaccard con k=20: %.3f" % (k, m.sum(), jac))
```

```
Local Outlier Factor
  Tamano del vecindario  : 20
  Observaciones marcadas : 107 (5.0 %)
  Factor LOF: min = 0.95 | mediana = 1.07 | max = 4.50

Sensibilidad al numero de vecinos (solapamiento con k = 20):
  k =  5: 107 marcadas, indice de Jaccard con k=20: 0.216
  k = 10: 107 marcadas, indice de Jaccard con k=20: 0.446
  k = 20: 107 marcadas, indice de Jaccard con k=20: 1.000
  k = 35: 107 marcadas, indice de Jaccard con k=20: 0.529
  k = 50: 107 marcadas, indice de Jaccard con k=20: 0.427
```

5.6 Comparación de los cinco detectores

Los cinco métodos ya han emitido su veredicto. La pregunta pendiente es cuál de ellos resulta realmente útil, y para responderla se recupera la etiqueta **NSP** que se había apartado al comienzo.

Listado 20. Celda 5.5. Evaluacion comparativa contra la verdad de referencia externa. Captura del cuaderno en Google Colab.

```
# Celda 5.5. Evaluacion comparativa contra la verdad de referencia externa.
# Objetivo: medir la utilidad real de cada detector usando NSP, que ningun
#   modelo ha visto. Se calcula el porcentaje de patologicos entre los marcados,
#   que actua como precision del detector; el lift, que es ese porcentaje
#   dividido por la tasa base; y el recall, que es la fraccion del total de
#   casos patologicos que el detector logra recuperar.
# Salidas: el DataFrame tabla_anomalias.

DETECTORES = {
    "Z-score (|z|>3)":      anom_zscore,
    "Tukey (1.5 RIC)":      anom_iqr,
    "Mahalanobis MCD (5 %)": anom_mahalanobis,
    "Isolation Forest (5 %)": anom_iforest,
    "LOF k=20 (5 %)":       anom_lof,
}

tasa_base = float((y_nsp == 3).mean())   # prevalencia de patologicos: 8,3 %
total_patologicos = int((y_nsp == 3).sum())

filas = []
for nombre, mascara in DETECTORES.items():
    n = int(mascara.sum())
    prec = float((y_nsp[mascara] == 3).mean())          # precision sobre NSP=3
    prec_23 = float((y_nsp[mascara] >= 2).mean())       # precision sobre no normales
    rec = float((y_nsp[mascara] == 3).sum() / total_patologicos)
    filas.append({
        "Metodo": nombre,
        "Marcadas": n,
        "% del conjunto": round(100 * n / len(Z), 1),
        "% patologicos": round(100 * prec, 1),
        "Lift": round(prec / tasa_base, 2),
        "% no normales": round(100 * prec_23, 1),
        "Recall NSP=3": round(100 * rec, 1),
    })

tabla_anomalias = pd.DataFrame(filas).set_index("Metodo")

print("EVALUACION DE LOS DETECTORES CONTRA LA ETIQUETA NSP\n")
print("Tasa base de casos patologicos: %.1f %%  (%d de %d)\n"
      % (100 * tasa_base, total_patologicos, len(y_nsp)))
print(tabla_anomalias.to_string())
print("\nUn lift de 1.00 significa que el detector no aporta nada sobre el azar.")

RES["tabla_anomalias"] = tabla_anomalias.reset_index().to_dict("records")
RES["tasa_base_nsp3"] = round(tasa_base, 4)
```

```
EVALUACION DE LOS DETECTORES CONTRA LA ETIQUETA NSP

Tasa base de casos patologicos: 8.3 %  (176 de 2126)

                        Marcadas  % del conjunto  % patologicos  Lift  % no normales  Recall NSP=3
Metodo
Z-score (|z|>3)              343            16.1           40.5  4.90           49.0          79.0
Tukey (1.5 RIC)             1220            57.4           13.7  1.65           30.4          94.9
Mahalanobis MCD (5 %)        106             5.0           41.5  5.01           49.1          25.0
Isolation Forest (5 %)       107             5.0           54.2  6.55           60.7          33.0
LOF k=20 (5 %)               107             5.0           17.8  2.14           39.3          10.8

Un lift de 1.00 significa que el detector no aporta nada sobre el azar.
```

Listado 21. Celda 5.6. Concordancia entre detectores y visualizacion. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 5.6. Concordancia entre detectores y visualizacion.
# Objetivo: medir cuanto coinciden los metodos entre si mediante el indice de
#   Jaccard, definido como el tamano de la interseccion dividido por el de la
#   union; visualizar las anomalias sobre la proyeccion PCA; y comparar el lift
#   de forma grafica.
# Salidas: las figuras fig_anomalias_jaccard y fig_anomalias_pca.

nombres = list(DETECTORES.keys())
jaccard = np.ones((len(nombres), len(nombres)))
for i, ni in enumerate(nombres):
    for j, nj in enumerate(nombres):
        a, b = DETECTORES[ni], DETECTORES[nj]
        jaccard[i, j] = (a & b).sum() / max((a | b).sum(), 1)

fig, (a1, a2) = plt.subplots(1, 2, figsize=(11, 4.0))

sns.heatmap(pd.DataFrame(jaccard, index=nombres, columns=nombres), annot=True,
            fmt=".2f", cmap=CMAP_SEQ, vmin=0, vmax=1, ax=a1,
            cbar_kws={"label": "indice de Jaccard"}, annot_kws={"size": 9})
a1.set_title("Concordancia entre detectores")
a1.tick_params(axis="x", rotation=30, labelsize=8)
a1.tick_params(axis="y", labelsize=8)

orden = tabla_anomalias["Lift"].sort_values()
colores = [UNIR_ROJO if v < 2 else UNIR_AMBAR if v < 5 else UNIR_CIAN for v in orden]
a2.barh(orden.index, orden.values, color=colores)
a2.axvline(1, color=UNIR_GRIS_OSC, ls="--", lw=1, label="Sin capacidad discriminante")
a2.set_xlabel("Lift sobre la tasa base de casos patologicos")
a2.set_title("Utilidad clinica de cada detector")
a2.tick_params(labelsize=9)
a2.legend(fontsize=9)
plt.tight_layout()
guardar("fig_anomalias_jaccard")

# Proyeccion PCA de las anomalias de los tres metodos multivariantes.
fig, ejes = plt.subplots(1, 3, figsize=(12, 3.9))
for eje, nombre in zip(ejes, ["Mahalanobis MCD (5 %)", "Isolation Forest (5 %)", "LOF k=20 (5 %)"]):
    m = DETECTORES[nombre]
    eje.scatter(Z2[~m, 0], Z2[~m, 1], s=6, c="#C9CDD1", label="Normal", alpha=0.6)
    eje.scatter(Z2[m, 0], Z2[m, 1], s=16, c=UNIR_ROJO, label="Anomalia", edgecolor="k", lw=0.2)
    eje.set_title("%s\n%.0f %% de patologicos entre las marcadas"
                  % (nombre, tabla_anomalias.loc[nombre, "% patologicos"]), fontsize=10)
    eje.set_xlabel("CP1 (%.0f %% var.)" % (100 * pca.explained_variance_ratio_[0]))
    eje.set_ylabel("CP2 (%.0f %% var.)" % (100 * pca.explained_variance_ratio_[1]))
    eje.legend(fontsize=9, markerscale=1.6)
fig.suptitle("Anomalias detectadas sobre las dos primeras componentes principales", fontsize=12)
plt.tight_layout()
guardar("fig_anomalias_pca")

[ ]
print("Indice de Jaccard entre los tres metodos multivariantes:")
print("  Isolation Forest y Mahalanobis: %.3f" % jaccard[nombres.index("Isolation Forest (5 %)"),
                                                          nombres.index("Mahalanobis MCD (5 %)")])
print("  Isolation Forest y LOF        : %.3f" % jaccard[nombres.index("Isolation Forest (5 %)"),
                                                          nombres.index("LOF k=20 (5 %)")])
print("  Mahalanobis y LOF             : %.3f" % jaccard[nombres.index("Mahalanobis MCD (5 %)"),
                                                          nombres.index("LOF k=20 (5 %)")])
RES["jaccard_if_lof"] = float(round(jaccard[nombres.index("Isolation Forest (5 %)"),
                                            nombres.index("LOF k=20 (5 %)")], 3))

Indice de Jaccard entre los tres metodos multivariantes:
  Isolation Forest y Mahalanobis: 0.365
  Isolation Forest y LOF        : 0.196
  Mahalanobis y LOF             : 0.158
```

Figura 7

Concordancia entre detectores y utilidad clínica de cada uno

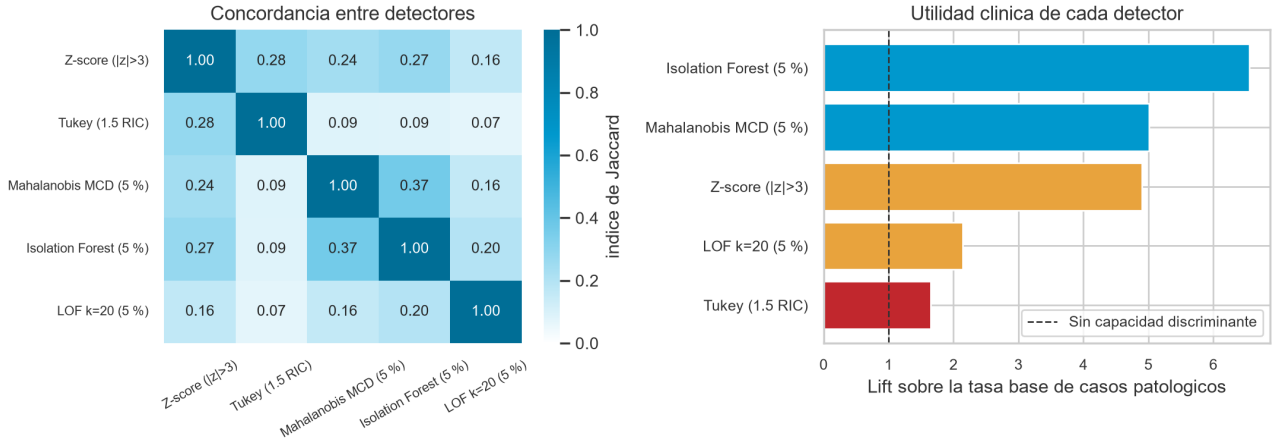

Nota. El índice de Jaccard mide la proporción de detecciones compartidas entre cada par de métodos. El lift es el cociente entre la proporción de casos patológicos entre los registros marcados y la tasa base del 8,3 %. Elaboración propia.

Figura 8

Anomalías detectadas por los tres métodos multivariantes

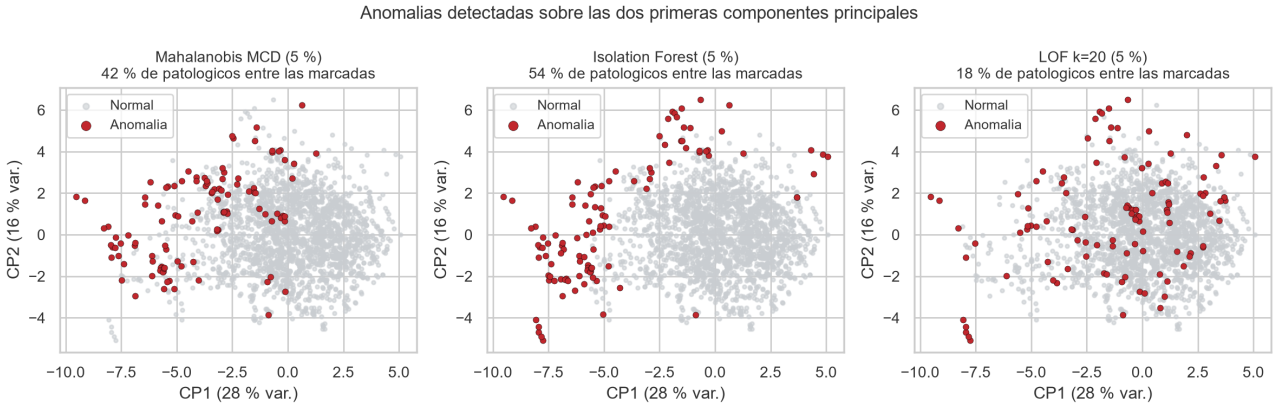

Nota. Proyección sobre las dos primeras componentes principales, que explican en conjunto el 43,3 % de la varianza. Elaboración propia.

La evaluación externa ordena los cinco detectores de forma inequívoca. Isolation Forest es el mejor con diferencia: de las 107 observaciones que marca, el 54,2 % son patológicas frente a una tasa base del 8,3 %, un lift de 6,55. Recupera el 33 % de todos los casos patológicos examinando solo el 5 % de los registros, de modo que una revisión manual de ese 5 % encontraría uno de cada dos casos graves.

La distancia de Mahalanobis robusta queda segunda con un lift de 5,01, resultado notable dado que su supuesto de normalidad está violado; el estimador robusto compensa buena parte del problema. El Z-score alcanza 4,90 pero a un coste inaceptable, marcando el 16 % del conjunto, y su recall del 79 % es engañoso porque se logra señalando una de cada seis observaciones.

El factor local de atipicidad es el peor de los multivariantes, con 2,14, por un motivo estructural: busca anomalías locales y en veinte dimensiones la densidad local se diluye, y además los trazados patológicos no forman puntos aislados sino una región periférica poblada que LOF interpreta como vecindario legítimo. La regla de Tukey no sirve en absoluto: lift de 1,65 marcando el 57 % del conjunto.

Un hallazgo transversal: los índices de Jaccard son bajos en toda la matriz, y en particular Isolation Forest y LOF comparten apenas el 20 % de sus detecciones. Ser una anomalía no es una propiedad absoluta del dato sino relativa al método, y por eso elegir detector exige un criterio externo de utilidad como el que aporta **NSP**.

Se adopta Isolation Forest al 5 % como detector de referencia. Sus 107 anomalías no se eliminan, porque en un problema clínico los atípicos son la señal de interés y no ruido; se conservan marcadas y en la sección siguiente se comprueba que el agrupamiento las ubica en un grupo propio.

6. Técnicas de agrupamiento

6.1 Planteamiento

El agrupamiento particiona las observaciones en grupos internamente homogéneos y mutuamente diferenciados sin recurrir a ninguna etiqueta. Se aplican tres algoritmos de familias distintas.

K-Means es particional, minimiza la inercia dentro de cada grupo, tiende a grupos esféricos de tamaño parecido y exige fijar su número. DBSCAN se basa en densidad: busca regiones densas separadas por regiones vacías, admite formas arbitrarias, no obliga a fijar el número y etiqueta como ruido lo que no encaja. El jerárquico aglomerativo con criterio de Ward construye fusiones sucesivas que minimizan el incremento de varianza, produce grupos compactos y anidados y permite decidir el número a posteriori, cortando el árbol.

Se emplean dos tipos de métricas. Las internas se calculan solo con los datos: el coeficiente de silueta, entre menos uno y uno, que mide cohesión frente a separación; el índice de Davies-Bouldin, que compara dispersión y separación y conviene bajo; y el de Calinski-Harabasz, que relaciona la varianza entre grupos con la interna y conviene alto. Las externas contrastan la partición con **NSP**, que no interviene en el ajuste: el índice de Rand ajustado y la información mutua normalizada, donde un cero equivale a una partición aleatoria.

6.2 K-Means: elección del número de grupos

Listado 22. Celda 6.1. Barrido del numero de grupos k para K-Means. Captura del cuaderno en Google Colab.

```python
# Celda 6.1. Barrido del numero de grupos k para K-Means.
# Objetivo: evaluar k entre 2 y 10 con cuatro criterios de validacion interna y
#   dos de validacion externa, para decidir el numero de grupos con evidencia y
#   no por intuicion.
# Nota: n_init = 20 relanza el algoritmo veinte veces con inicializaciones
#   distintas y conserva la mejor, lo que mitiga su dependencia del arranque
#   aleatorio, ya que K-Means solo garantiza alcanzar un optimo local.
# Salidas: el DataFrame barrido_k.

RANGO_K = range(2, 11)
registros = []

for k in RANGO_K:
    modelo = KMeans(n_clusters=k, n_init=20, random_state=SEMILLA).fit(Z)
    etiquetas = modelo.labels_
    registros.append({
        "k": k,
        "Inercia": round(modelo.inertia_, 1),
        "Silueta": round(silhouette_score(Z, etiquetas), 4),
        "Davies-Bouldin": round(davies_bouldin_score(Z, etiquetas), 4),
        "Calinski-Harabasz": round(calinski_harabasz_score(Z, etiquetas), 1),
        "ARI vs NSP": round(adjusted_rand_score(y_nsp, etiquetas), 4),
        "NMI vs NSP": round(normalized_mutual_info_score(y_nsp, etiquetas), 4),
    })

barrido_k = pd.DataFrame(registros).set_index("k")
print("Barrido del numero de grupos (validacion interna y externa):")
print(barrido_k.to_string())

# Deteccion analitica del codo de la curva de inercia. Se define como el punto
# de maxima distancia perpendicular a la recta que une el primer y el ultimo
# valor de la curva, lo que evita la lectura subjetiva del grafico.
ks = np.array(list(RANGO_K), dtype=float)
inercias = barrido_k["Inercia"].values.astype(float)
p1 = np.array([ks[0], inercias[0]])
p2 = np.array([ks[-1], inercias[-1]])
direccion = (p2 - p1) / np.linalg.norm(p2 - p1)
distancias = []
for x, yv in zip(ks, inercias):
    v = np.array([x, yv]) - p1
    distancias.append(np.linalg.norm(v - np.dot(v, direccion) * direccion))
k_codo = int(ks[int(np.argmax(distancias))])
print("\nCodo detectado analiticamente en k =", k_codo)

RES["barrido_k"] = barrido_k.reset_index().to_dict("records")
RES["k_codo"] = k_codo
```

```
Barrido del numero de grupos (validacion interna y externa):
   Inercia  Silueta  Davies-Bouldin  Calinski-Harabasz  ARI vs NSP  NMI vs NSP
k
2  35166.1   0.1832          2.0107              444.2      0.0160      0.0864
3  31323.9   0.1572          1.9233              379.4      0.2142      0.2224
4  28241.2   0.1543          1.8186              357.6      0.0908      0.1822
5  26076.2   0.1610          1.5396              334.4      0.0883      0.1780
6  24366.9   0.1522          1.6241              315.9      0.1224      0.2257
7  22783.4   0.1568          1.4705              305.9      0.1261      0.2236
8  21572.2   0.1479          1.5920              293.8      0.1012      0.2172
9  20469.0   0.1558          1.5537              285.1      0.0788      0.2030
10 19671.6   0.1603          1.5635              273.1      0.0681      0.2003

Codo detectado analiticamente en k = 5
```

Listado 23. Celda 6.2. Representacion grafica de los criterios de seleccion de k. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.2. Representacion grafica de los criterios de seleccion de k.
# Objetivo: mostrar en un solo panel los cuatro criterios internos y los dos
#   externos, para que el conflicto entre ellos resulte visible de un vistazo.
# Salidas: la figura fig_kmeans_seleccion.

fig, ejes = plt.subplots(2, 3, figsize=(11.5, 6.0))

paneles = [
    ("Inercia", "Metodo del codo", UNIR_CIAN, None),
    ("Silueta", "Coeficiente de silueta (mayor = mejor)", UNIR_CIAN_OSC, "max"),
    ("Davies-Bouldin", "Indice Davies-Bouldin (menor = mejor)", UNIR_ROJO, "min"),
    ("Calinski-Harabasz", "Indice Calinski-Harabasz (mayor = mejor)", UNIR_GRIS, "max"),
    ("ARI vs NSP", "Rand ajustado frente a NSP (validacion externa)", UNIR_AMBAR, "max"),
    ("NMI vs NSP", "Informacion mutua normalizada frente a NSP", UNIR_CIAN_CLA, "max"),
]

for eje, (columna, titulo, color, optimo) in zip(ejes.flatten(), paneles):
    serie = barrido_k[columna]
    eje.plot(serie.index, serie.values, "o-", color=color, lw=1.8)
    # Se marca el k optimo segun ese criterio concreto.
    if optimo == "max":
        k_opt = serie.idxmax()
    elif optimo == "min":
        k_opt = serie.idxmin()
    else:
        k_opt = k_codo
    eje.axvline(k_opt, ls="--", color=UNIR_GRIS, lw=1)
    eje.set_title(titulo + "  (k = %d)" % k_opt, fontsize=10)
    eje.set_xlabel("Numero de grupos k")
    eje.set_xticks(list(RANGO_K))

fig.suptitle("Criterios para elegir el numero de grupos en K-Means", fontsize=13)
plt.tight_layout()
guardar("fig_kmeans_seleccion")
```

Figura 9

Criterios internos y externos para elegir el número de grupos

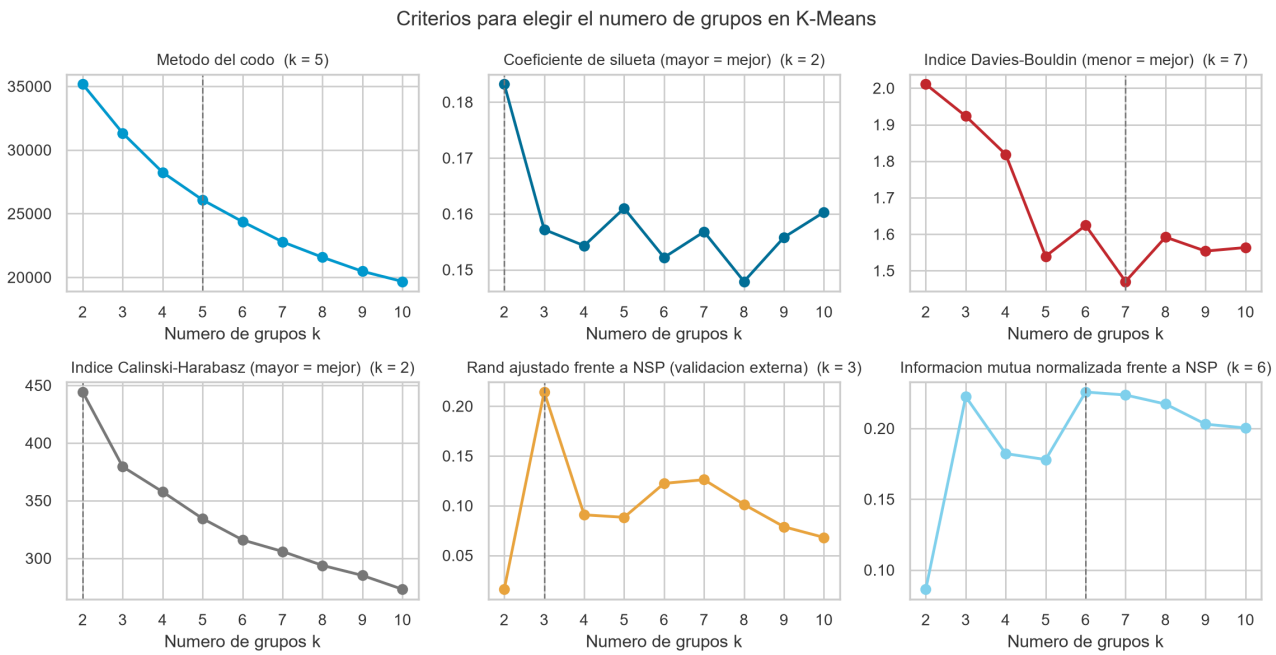

Nota. La línea vertical discontinua señala el valor óptimo de k según cada criterio por separado. Los dos paneles inferiores corresponden a la validación externa frente a la etiqueta NSP. Elaboración propia.

Los criterios no coinciden entre sí, y esa discrepancia es el hallazgo más instructivo del apartado. La curva de inercia decrece suavemente, sin codo pronunciado; el criterio analítico lo sitúa en k igual a 5, pero la curvatura es débil, señal de que no hay grupos fuertemente separados. La silueta alcanza su máximo en k igual a 2, con 0,183, y todo el barrido queda por debajo de 0,19 cuando con grupos nítidos se esperaría más de 0,5. Davies-Bouldin alcanza su mínimo en k igual a 7, con 1,47, y Calinski-Harabasz decrece de forma monótona, favoreciendo el menor k posible. Los tres criterios internos apuntan a tres valores distintos: 5, 2 y 2.

La validación externa sí es concluyente. El índice de Rand ajustado alcanza su máximo inequívoco en k igual a 3, con 0,214, y cae a menos de la mitad en k igual a 4, donde vale 0,091. La información mutua normalizada es prácticamente máxima ahí también, con 0,222 frente a los

0,226 de k igual a 6, que exige el doble de grupos para no ganar nada.

Se adopta k igual a 3 por dos razones independientes que apuntan al mismo valor. La primaria es de dominio: el problema clínico está definido sobre tres estados fetales, de manera que elegir tres grupos responde a la estructura conocida del fenómeno y no a los datos, lo que evita la circularidad. La secundaria es la confirmación externa: que el índice de Rand alcance su máximo precisamente ahí indica que esa estructura de tres niveles existe en los descriptores numéricos y no es solo una convención médica.

Conviene señalar que la silueta habría llevado a dos grupos, partición cuyo índice de Rand ajustado es prácticamente nulo, de 0,016. Los índices internos miden geometría, no significado.

6.3 Perfilado e interpretación de los grupos

Listado 24. Celda 6.3. Ajuste final de K-Means y perfilado de los grupos. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.3. Ajuste final de K-Means y perfilado de los grupos.
# Objetivo: ajustar el modelo definitivo y caracterizar cada grupo. Un
#   agrupamiento sin interpretacion no pasa de ser un vector de numeros: el
#   valor del analisis esta en explicar que distingue a cada grupo.
# Salidas: las etiquetas etq_kmeans, el DataFrame centroides y la figura
#   fig_kmeans_perfil.

K_ELEGIDO = 3
kmeans = KMeans(n_clusters=K_ELEGIDO, n_init=50, random_state=SEMILLA).fit(Z)
etq_kmeans = kmeans.labels_

# Los centroides estan en unidades estandarizadas, de modo que cada valor indica
# cuantas desviaciones tipicas por encima o por debajo de la media general se
# situa el grupo en esa variable.
centroides = pd.DataFrame(kmeans.cluster_centers_, columns=VARIABLES_MODELO)
centroides.index = ["Grupo %d" % i for i in range(K_ELEGIDO)]

tamanos = pd.Series(etq_kmeans).value_counts().sort_index()
print("Tamano de los grupos:")
for i, n in tamanos.items():
    print("  Grupo %d: %4d observaciones (%.1f %%)" % (i, n, 100 * n / len(Z)))
print("\nSilueta global: %.4f" % silhouette_score(Z, etq_kmeans))

plt.figure(figsize=(11, 3.1))
sns.heatmap(centroides, annot=True, fmt=".2f", cmap=CMAP_DIV, center=0,
            vmin=-2.2, vmax=2.2, linewidths=0.4, annot_kws={"size": 8},
            cbar_kws={"label": "desviaciones tipicas"})
plt.title("Perfil de los centroides de K-Means (k = 3)")
plt.tight_layout()
guardar("fig_kmeans_perfil")

print("\nVariables mas caracteristicas de cada grupo:\n")
for g in range(K_ELEGIDO):
    fila = centroides.loc["Grupo %d" % g]
    destacadas = fila.reindex(fila.abs().sort_values(ascending=False).index).head(6)
    texto = ", ".join(["%s %+.2f" % (v, x) for v, x in destacadas.items()])
    print("  Grupo %d (n = %d): %s" % (g, tamanos[g], texto))

RES["tamanos_kmeans"] = {int(i): int(n) for i, n in tamanos.items()}
RES["silueta_kmeans"] = round(float(silhouette_score(Z, etq_kmeans)), 4)
RES["centroides_kmeans"] = centroides.round(2).to_dict("index")
```

```
Tamano de los grupos:
  Grupo 0:  204 observaciones (9.6 %)
  Grupo 1:  835 observaciones (39.3 %)
  Grupo 2: 1087 observaciones (51.1 %)

Silueta global: 0.1572

Variables mas caracteristicas de cada grupo:

  Grupo 0 (n = 204): DP +2.21, Mean -1.86, Variance +1.73, DL +1.66, Median -1.56, Mode -1.55
  Grupo 1 (n = 835): Min +0.88, MSTV -0.75, LB +0.72, Mean +0.70, ALTV +0.67, Median +0.64
  Grupo 2 (n = 1087): ASTV -0.49, Min -0.47, LB -0.45, ALTV -0.42, MSTV +0.34, MLTV +0.29
```

Figura 10

Perfil de los centroides de K-Means con tres grupos

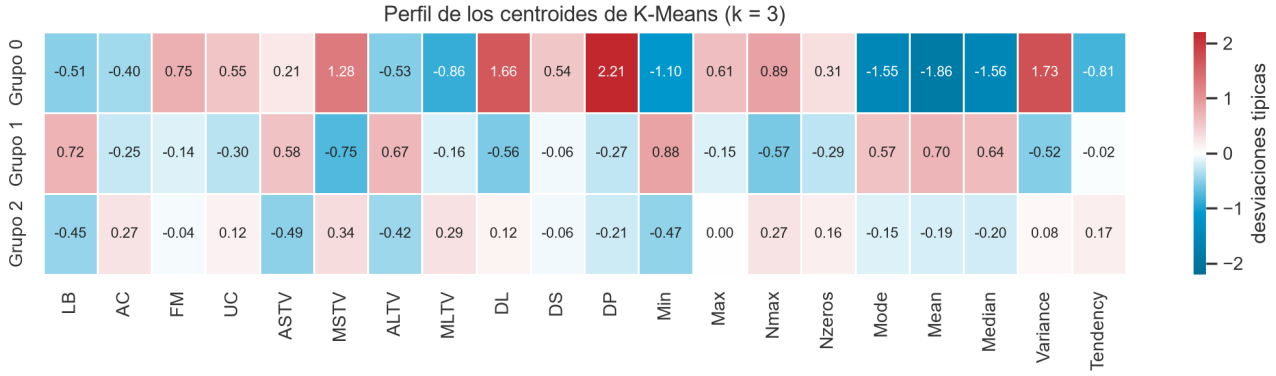

Nota. Cada celda indica cuántas desviaciones típicas por encima o por debajo de la media general se sitúa el grupo en esa variable. Elaboración propia.

Listado 25. Celda 6.4. Validacion externa: contraste de los grupos con el diagnostico NSP. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.4. Validacion externa: contraste de los grupos con el diagnostico NSP.
# Objetivo: comprobar si los grupos hallados sin supervision se corresponden con
#   los estados fetales que diagnosticaron los obstetras.
# Salidas: la tabla de contingencia y la figura fig_kmeans_nsp.

NOMBRES_NSP = {1: "Normal", 2: "Sospechoso", 3: "Patologico"}

contingencia = pd.crosstab(
    pd.Series(etq_kmeans, name="Grupo K-Means"),
    pd.Series([NOMBRES_NSP[v] for v in y_nsp], name="Diagnostico NSP"),
)
contingencia = contingencia[["Normal", "Sospechoso", "Patologico"]]
porcentajes = (100 * contingencia.div(contingencia.sum(axis=1), axis=0)).round(1)

print("Contingencia (conteos y, entre parentesis, porcentaje por fila):\n")
print((contingencia.astype(str) + " (" + porcentajes.astype(str) + " %)").to_string())

ari = adjusted_rand_score(y_nsp, etq_kmeans)
nmi = normalized_mutual_info_score(y_nsp, etq_kmeans)
# Pureza: proporcion de aciertos si a cada grupo se le asignara su clase mayoritaria.
pureza = contingencia.max(axis=1).sum() / contingencia.values.sum()
# Prueba chi-cuadrado de independencia entre grupo y diagnostico.
chi2, p_valor, gl, _ = stats.chi2_contingency(contingencia.values)

print("\nValidacion externa: ARI %.4f | NMI %.4f | pureza %.4f" % (ari, nmi, pureza))
print("Chi-cuadrado de independencia: %.1f (gl = %d), p = %.3e" % (chi2, gl, p_valor))
print("Con p < 0.001, la asociacion con el diagnostico no es atribuible al azar.")

fig, (a1, a2) = plt.subplots(1, 2, figsize=(11, 3.9))

porcentajes.plot(kind="bar", stacked=True, ax=a1,
                 color=[UNIR_CIAN, UNIR_AMBAR, UNIR_ROJO], width=0.7)
a1.axhline(100 * (y_nsp == 1).mean(), ls="--", color=UNIR_GRIS_OSC, lw=1,
           label="Tasa base de normales (%.0f %%)" % (100 * (y_nsp == 1).mean()))
a1.set_ylabel("Composicion del grupo (%)")
a1.set_xlabel("")
a1.set_title("Composicion diagnostica de cada grupo")
a1.tick_params(axis="x", rotation=0)
a1.legend(fontsize=9, loc="lower right")

for g in range(K_ELEGIDO):
    m = etq_kmeans == g
    a2.scatter(Z2[m, 0], Z2[m, 1], s=7, alpha=0.6, label="Grupo %d (n=%d)" % (g, m.sum()))
centros_2d = pca.transform(kmeans.cluster_centers_)[:, :2]
a2.scatter(centros_2d[:, 0], centros_2d[:, 1], s=130, marker="X",
           c=UNIR_GRIS_OSC, edgecolor="white", lw=1.5, label="Centroides", zorder=5)
a2.set_xlabel("CP1 (%.0f %% var.)" % (100 * pca.explained_variance_ratio_[0]))
a2.set_ylabel("CP2 (%.0f %% var.)" % (100 * pca.explained_variance_ratio_[1]))
[ ]
a2.set_title("Grupos sobre las componentes principales")
a2.legend(fontsize=9, markerscale=1.8)
plt.tight_layout()
guardar("fig_kmeans_nsp")

RES["ari_kmeans"] = round(float(ari), 4)
RES["nmi_kmeans"] = round(float(nmi), 4)
RES["pureza_kmeans"] = round(float(pureza), 4)
RES["contingencia_kmeans"] = contingencia.to_dict("index")
RES["porcentajes_kmeans"] = porcentajes.to_dict("index")
```

```
Contingencia (conteos y, entre parentesis, porcentaje por fila):

Diagnostico NSP          Normal    Sospechoso    Patologico
Grupo K-Means
0                   88 (43.1 %)    11 (5.4 %)  105 (51.5 %)
1                  512 (61.3 %)   259 (31.0 %)    64 (7.7 %)
2                 1055 (97.1 %)    25 (2.3 %)     7 (0.6 %)

Validacion externa: ARI 0.2142 | NMI 0.2224 | pureza 0.7865
Chi-cuadrado de independencia: 941.4 (gl = 4), p = 1.768e-202
Con p < 0.001, la asociacion con el diagnostico no es atribuible al azar.
```

Figura 11

Composición diagnóstica de los grupos y proyección sobre el plano principal

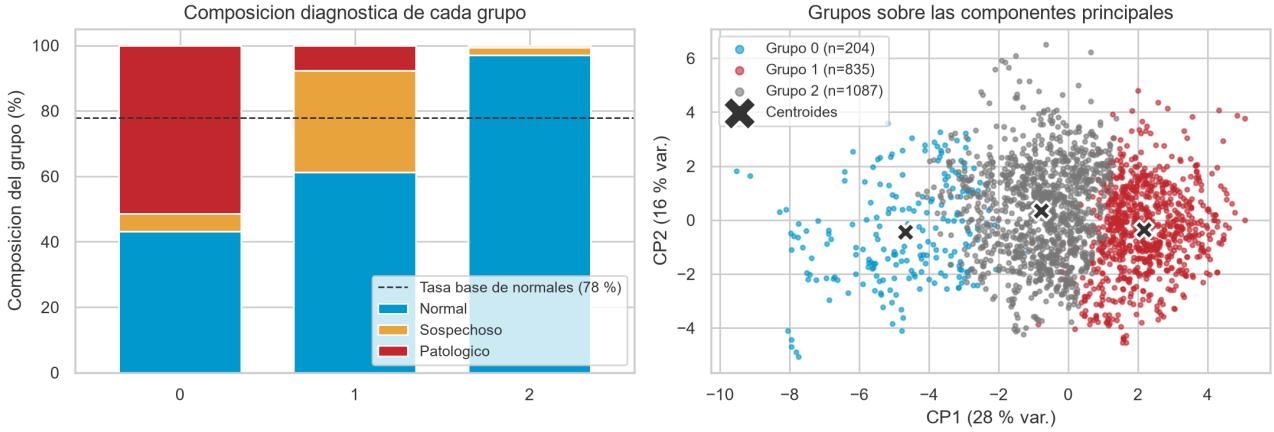

Nota. A la izquierda, reparto de los tres diagnósticos dentro de cada grupo. A la derecha, los grupos sobre las dos primeras componentes principales, con los centroides marcados con una equis. Elaboración propia.

Listado 26. Celda 6.5. Relacion entre los grupos y las anomalias de la seccion 5. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.5. Relacion entre los grupos y las anomalias de la seccion 5.
# Objetivo: comprobar si las dos tecnicas, aplicadas de forma independiente,
#   convergen. Si el agrupamiento aisla un grupo minoritario y ese mismo grupo
#   concentra las anomalias de Isolation Forest, ambas estan describiendo la
#   misma estructura subyacente.

cruce = pd.crosstab(
    pd.Series(etq_kmeans, name="Grupo K-Means"),
    pd.Series(np.where(anom_iforest, "Anomalia IF", "Normal IF"), name="Isolation Forest"),
)
cruce_pct = (100 * cruce.div(cruce.sum(axis=1), axis=0)).round(1)

print("Anomalias de Isolation Forest por grupo de K-Means "
      "(tasa global: 5.0 %):\n")
print(pd.DataFrame({"Anomalias": cruce["Anomalia IF"],
                    "Normales": cruce["Normal IF"],
                    "% anomalias": cruce_pct["Anomalia IF"]}).to_string())

RES["anomalias_por_grupo"] = cruce_pct["Anomalia IF"].round(1).to_dict()

Anomalias de Isolation Forest por grupo de K-Means (tasa global: 5.0 %):

                 Anomalias  Normales  % anomalias
Grupo K-Means
0                       78       126         38.2
1                        8       827          1.0
2                       21      1066          1.9
```

El perfilado convierte tres etiquetas numéricas en tres fenotipos clínicos reconocibles.

El grupo 0, con 204 observaciones y el 9,6 % del conjunto, es el trazado comprometido: pequeño y extremo. Presenta **`DP`** en 2,21 y **`DL`** en 1,66 desviaciones típicas por encima de la media, es decir, abundantes deceleraciones prolongadas y ligeras; **`Variance`** en 1,73 y **`MSTV`** en 1,28, variabilidad errática; y tendencia central muy baja, con **`Mean`** en menos 1,86, **`Median`** en menos 1,56, **`Mode`** en menos 1,55 y **`Min`** en menos 1,10, o sea bradicardia. Su composición es la más severa, con un 51,5 % de patológicos frente al 8,3 % de base: este único grupo, menos de una décima parte del conjunto, contiene el 60 % de todos los casos patológicos, y el 38 % de sus miembros fueron marcados por Isolation Forest cuando en los otros dos no llega al 2 %.

El grupo 1, con 835 observaciones y el 39,3 %, corresponde a variabilidad reducida con taquicardia relativa: **`LB`** en 0,72 y **`Min`** en 0,88, línea de base elevada; **`ASTV`** en 0,58 y **`ALTV`** en 0,67, mucho tiempo con variabilidad anormal; y **`MSTV`** en menos 0,75, variabilidad efectiva baja. Reúne un 61,3 % de normales pero también un 31,0 % de sospechosos, casi el triple de la tasa base. Es el grupo de vigilancia.

El grupo 2, con 1 087 observaciones y el 51,1 %, es el trazado tranquilizador: **`AC`** en 0,27 y **`MLTV`** en 0,29, con aceleraciones y buena variabilidad a largo plazo, junto a **`ASTV`** en menos 0,49 y **`ALTV`** en

menos 0,42. Un 97,1 % de casos normales y apenas 7 patológicos.

El índice de Rand ajustado de 0,214 puede parecer modesto, pero la prueba chi-cuadrado descarta el azar y la contingencia muestra un gradiente monótono de gravedad. El valor moderado tiene explicación: el agrupamiento separa muy bien los extremos, los grupos 0 y 2, pero no aísla la categoría de los sospechosos, que es una zona de transición y no un fenotipo con frontera propia. Que el grupo más anómalo según K-Means sea también donde se concentran las anomalías de Isolation Forest refuerza que la estructura hallada es real.

6.4 DBSCAN

Listado 27. Celda 6.6. DBSCAN: eleccion de eps mediante el grafico de k-distancias. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.6. DBSCAN: eleccion de eps mediante el grafico de k-distancias.
# Objetivo: DBSCAN agrupa regiones densas y etiqueta como ruido, con el valor
#   -1, lo que queda fuera. Necesita dos parametros: min_samples, que es el
#   numero minimo de puntos para considerar densa una zona, y eps, que es el
#   radio del vecindario. El valor de eps se elige con la heuristica de Ester y
#   colaboradores (1996): se ordena la distancia de cada punto a su k-esimo
#   vecino y se busca el codo de la curva resultante.
# Nota: DBSCAN se aplica sobre el espacio reducido por PCA y no sobre las veinte
#   variables originales, porque en dimension alta las distancias se concentran
#   y la nocion de densidad pierde contraste.
# Salidas: la figura fig_dbscan_kdist y el valor EPS_ELEGIDO.

Z_dbscan = Z_pca80
MIN_SAMPLES = 10
print("Espacio de trabajo de DBSCAN:", Z_dbscan.shape[1], "componentes principales",
      "(%.0f %% de la varianza)" % (100 * np.cumsum(pca.explained_variance_ratio_)[Z_dbscan.shape[1] - 1]))

vecinos = NearestNeighbors(n_neighbors=MIN_SAMPLES).fit(Z_dbscan)
distancias, _ = vecinos.kneighbors(Z_dbscan)
k_dist = np.sort(distancias[:, -1])

plt.figure(figsize=(6.5, 3.4))
plt.plot(k_dist, lw=1.6, color=UNIR_CIAN)
plt.axhline(2.0, color=UNIR_ROJO, ls="--", lw=1, label="eps = 2.0 (valor elegido)")
plt.xlabel("Observaciones ordenadas por distancia")
plt.ylabel("Distancia al vecino n. %d" % MIN_SAMPLES)
plt.title("Grafico de k-distancias para la eleccion de eps")
plt.legend(fontsize=9)
plt.tight_layout()
guardar("fig_dbscan_kdist")

print("\nPercentiles de la distancia al vecino n. %d:" % MIN_SAMPLES)
for p in [50, 75, 90, 95, 99]:
    print("  P%2d = %.2f" % (p, np.percentile(k_dist, p)))

EPS_ELEGIDO = 2.0
```

```
Espacio de trabajo de DBSCAN: 9 componentes principales (83 % de la varianza)

Percentiles de la distancia al vecino n. 10:
  P50 = 1.48
  P75 = 1.88
  P90 = 2.42
  P95 = 2.94
  P99 = 5.14
```

Figura 12

Gráfico de k-distancias para la elección del parámetro eps

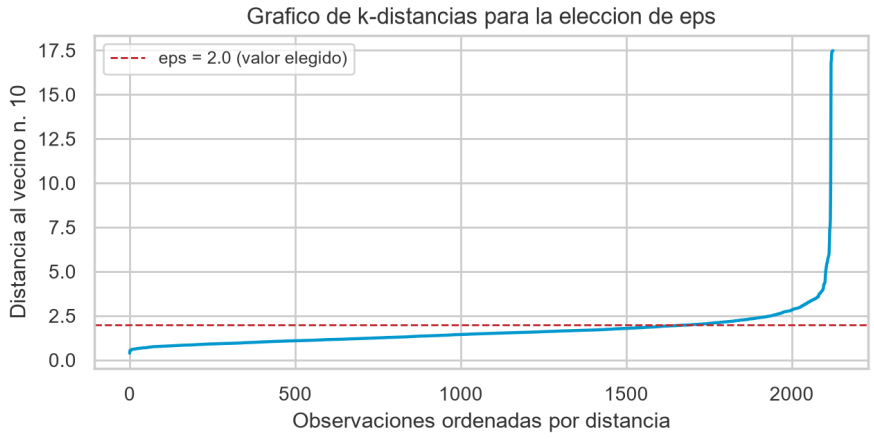

Nota. Distancia de cada observación a su décimo vecino más próximo, ordenada de menor a mayor. El codo de la curva orienta la elección del radio de vecindario. Elaboración propia.

Listado 28. Celda 6.7. Barrido de parametros y ajuste final de DBSCAN. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.7. Barrido de parametros y ajuste final de DBSCAN.
# Objetivo: explorar la sensibilidad de DBSCAN al par (eps, min_samples) y
#   ajustar el modelo definitivo. La silueta se calcula excluyendo el ruido,
#   porque los puntos etiquetados con -1 no constituyen un grupo.
# Salidas: las etiquetas etq_dbscan y el DataFrame barrido_dbscan.

registros = []
for eps in [1.6, 1.8, 2.0, 2.2, 2.5, 3.0]:
    for ms in [10, 16, 20]:
        etiquetas = DBSCAN(eps=eps, min_samples=ms).fit_predict(Z_dbscan)
        n_grupos = len(set(etiquetas)) - (1 if -1 in etiquetas else 0)
        n_ruido = int((etiquetas == -1).sum())
        # La silueta requiere al menos dos grupos entre los puntos no ruidosos.
        if n_grupos > 1:
            sil = silhouette_score(Z_dbscan[etiquetas != -1], etiquetas[etiquetas != -1])
        else:
            sil = np.nan
        registros.append({
            "eps": eps, "min_samples": ms, "Grupos": n_grupos,
            "Ruido": n_ruido, "% ruido": round(100 * n_ruido / len(Z), 1),
            "Silueta (sin ruido)": round(sil, 4) if not np.isnan(sil) else None,
            "ARI vs NSP": round(adjusted_rand_score(y_nsp, etiquetas), 4),
        })

barrido_dbscan = pd.DataFrame(registros)

# De las 18 combinaciones se imprimen solo las que llegan a formar mas de un
# grupo, porque son las unicas comparables; de las demas basta con saber cuantas
# son, ya que todas devuelven un unico grupo mas ruido.
un_solo_grupo = int((barrido_dbscan["Grupos"] <= 1).sum())
print("Sensibilidad de DBSCAN: de las %d combinaciones probadas, %d devuelven un"
      % (len(barrido_dbscan), un_solo_grupo))
print("unico grupo mas ruido. Las %d restantes son:\n"
      % (len(barrido_dbscan) - un_solo_grupo))
print(barrido_dbscan[barrido_dbscan["Grupos"] > 1].to_string(index=False))

dbscan = DBSCAN(eps=EPS_ELEGIDO, min_samples=MIN_SAMPLES)
etq_dbscan = dbscan.fit_predict(Z_dbscan)

n_grupos_db = len(set(etq_dbscan)) - (1 if -1 in etq_dbscan else 0)
ruido_db = etq_dbscan == -1

tamanos_db = ", ".join(
    "%s: %d" % ("ruido" if g == -1 else "grupo %d" % g, (etq_dbscan == g).sum())
    for g in sorted(set(etq_dbscan)))
print("\nDBSCAN definitivo (eps = %.1f, min_samples = %d): %d grupos y %d puntos "
      "de ruido (%.1f %%)"
      % (EPS_ELEGIDO, MIN_SAMPLES, n_grupos_db, ruido_db.sum(), 100 * ruido_db.mean()))
[ ]
print("  Tamanos -> %s" % tamanos_db)

RES["dbscan_n_grupos"] = int(n_grupos_db)
RES["dbscan_ruido"] = int(ruido_db.sum())
RES["barrido_dbscan"] = barrido_dbscan.to_dict("records")
```

```
Sensibilidad de DBSCAN: de las 18 combinaciones probadas, 11 devuelven un
unico grupo mas ruido. Las 7 restantes son:

 eps  min_samples  Grupos  Ruido  % ruido  Silueta (sin ruido)  ARI vs NSP
 1.8          10       2    300     14.1               0.3936      0.1597
 2.0          10       2    213     10.0               0.3874      0.1965
 2.0          16       2    268     12.6               0.3747      0.1784
 2.2          10       2    139      6.5               0.3837      0.2047
 2.2          16       2    178      8.4               0.3666      0.2116
 2.2          20       2    203      9.5               0.3683      0.2003
 3.0          10       2     38      1.8               0.4471      0.0705

DBSCAN definitivo (eps = 2.0, min_samples = 10): 2 grupos y 213 puntos de ruido (10.0 %)
  Tamanos -> ruido: 213, grupo 0: 1885, grupo 1: 28
```

Listado 29. Celda 6.8. Interpretacion de la salida de DBSCAN. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.8. Interpretacion de la salida de DBSCAN.
# Objetivo: contrastar los grupos y el ruido de DBSCAN con el diagnostico NSP y
#   con las anomalias de Isolation Forest.
# Salidas: las tablas impresas y la figura fig_dbscan.

etiquetas_legibles = ["Ruido" if g == -1 else "Grupo %d" % g for g in etq_dbscan]
cont_db = pd.crosstab(
    pd.Series(etiquetas_legibles, name="DBSCAN"),
    pd.Series([NOMBRES_NSP[v] for v in y_nsp], name="Diagnostico NSP"),
)[["Normal", "Sospechoso", "Patologico"]]

pct_db = (100 * cont_db.div(cont_db.sum(axis=1), axis=0)).round(1)
print("Contingencia DBSCAN frente a NSP "
      "(conteos y, entre parentesis, porcentaje por fila):\n")
print((cont_db.astype(str) + " (" + pct_db.astype(str) + " %)").to_string())

print("\nValidacion externa: ARI = %.4f | NMI = %.4f"
      % (adjusted_rand_score(y_nsp, etq_dbscan),
         normalized_mutual_info_score(y_nsp, etq_dbscan)))

jaccard_ruido = (ruido_db & anom_iforest).sum() / (ruido_db | anom_iforest).sum()
print("\nCoincidencia entre el ruido de DBSCAN y las anomalias de Isolation Forest:")
print("  Indice de Jaccard: %.3f" % jaccard_ruido)
print("  Puntos marcados por ambos metodos: %d" % (ruido_db & anom_iforest).sum())

fig, (a1, a2) = plt.subplots(1, 2, figsize=(11, 4.0))
```

```python
for g in sorted(set(etq_dbscan)):
    m = etq_dbscan == g
    if g == -1:
        a1.scatter(Z2[m, 0], Z2[m, 1], s=14, c=UNIR_ROJO, marker="x",
                   label="Ruido (n=%d)" % m.sum())
    else:
        a1.scatter(Z2[m, 0], Z2[m, 1], s=7, alpha=0.6, label="Grupo %d (n=%d)" % (g, m.sum()))
a1.set_xlabel("CP1"); a1.set_ylabel("CP2")
a1.set_title("Resultado de DBSCAN (eps = %.1f, min_samples = %d)" % (EPS_ELEGIDO, MIN_SAMPLES))
a1.legend(fontsize=9, markerscale=1.6)

colores_nsp = {1: UNIR_CIAN, 2: UNIR_AMBAR, 3: UNIR_ROJO}
for v in [1, 2, 3]:
    m = y_nsp == v
    a2.scatter(Z2[m, 0], Z2[m, 1], s=7, alpha=0.65, c=colores_nsp[v],
               label="%s (n=%d)" % (NOMBRES_NSP[v], m.sum()))
a2.set_xlabel("CP1"); a2.set_ylabel("CP2")
a2.set_title("Referencia: diagnostico real NSP")
a2.legend(fontsize=9, markerscale=1.8)
plt.tight_layout()
guardar("fig_dbscan")

RES["dbscan_ari"] = round(float(adjusted_rand_score(y_nsp, etq_dbscan)), 4)
RES["jaccard_ruido_if"] = round(float(jaccard_ruido), 3)
```

```
Contingencia DBSCAN frente a NSP (conteos y, entre parentesis, porcentaje por fila):

Diagnostico NSP          Normal    Sospechoso    Patologico
DBSCAN
Grupo 0           1537 (81.5 %)  272 (14.4 %)    76 (4.0 %)
Grupo 1               0 (0.0 %)    0 (0.0 %)   28 (100.0 %)
Ruido              118 (55.4 %)   23 (10.8 %)   72 (33.8 %)

Validacion externa: ARI = 0.1965 | NMI = 0.1340

Coincidencia entre el ruido de DBSCAN y las anomalias de Isolation Forest:
  Indice de Jaccard: 0.455
  Puntos marcados por ambos metodos: 100
```

Figura 13

Resultado de DBSCAN frente al diagnóstico real

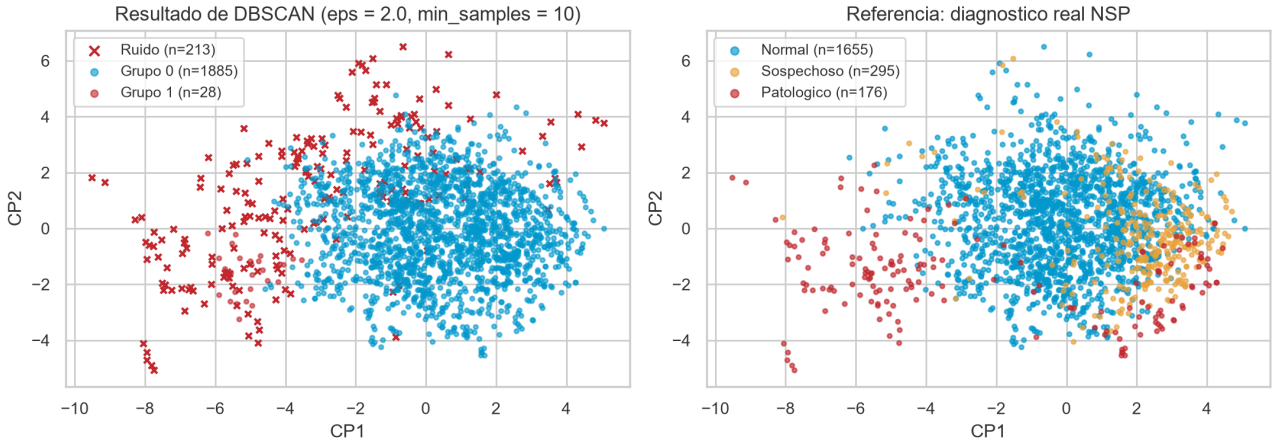

Nota. A la izquierda, los grupos y el ruido que identifica el algoritmo. A la derecha, las mismas observaciones coloreadas según la etiqueta NSP, que el algoritmo no ha utilizado. Elaboración propia.

DBSCAN no produce una partición útil, y el motivo es informativo. Encuentra dos grupos y 213 puntos de ruido con un reparto radicalmente asimétrico: un grupo absorbe 1 885 observaciones, el 88,7 % del conjunto, y el otro apenas 28.

El barrido demuestra que es estructural y no una mala elección de eps: en once de las dieciocho combinaciones probadas devuelve un único grupo más ruido, y en las siete restantes el segundo nunca supera unas decenas de puntos. Los datos no tienen zonas de baja densidad que separen regiones densas, sino una nube única cuya densidad decae de forma continua hacia la periferia. DBSCAN necesita valles y aquí no los hay.

Ahora bien, el grupo 1, de 28 observaciones, está compuesto íntegramente por casos patológicos: ha aislado un fenotipo extremo con precisión perfecta, aunque cubre solo el 16 % de los patológicos. El ruido también informa: de los 213 puntos etiquetados con menos uno, el 33,8 % son patológicos, cuatro veces la tasa base, y su índice de Jaccard con las anomalías de Isolation Forest es de 0,455, compartiendo 100 puntos, la concordancia más alta entre dos métodos de todo el trabajo.

En este conjunto DBSCAN rinde mejor como detector de anomalías que como algoritmo de agrupamiento. Su índice de Rand ajustado global, 0,197, es comparable al de K-Means, pero se consigue por otra vía: no por particionar bien sino por apartar los casos extremos. Coherentemente, su información mutua normalizada, 0,134, es muy inferior a la de K-Means, 0,222, porque deja el 88,7 % de los registros en un grupo indiferenciado.

6.5 Agrupamiento jerárquico aglomerativo

Listado 30. Celda 6.9. Agrupamiento jerarquico: dendrograma y criterios de enlace. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.9. Agrupamiento jerarquico: dendrograma y criterios de enlace.
# Objetivo: construir la jerarquia completa de fusiones y comparar tres
#   criterios de enlace. El dendrograma permite decidir el numero de grupos a
#   posteriori, observando a que altura se producen las fusiones mas costosas.
# Salidas: la figura fig_dendrograma, las etiquetas etq_jerarquico y el
#   DataFrame comparacion_enlaces.

# linkage() de SciPy calcula la jerarquia completa. El metodo de Ward minimiza
# el incremento de varianza intragrupo en cada fusion, que es el criterio mas
# proximo al que emplea K-Means.
matriz_enlace = linkage(Z, method="ward")

plt.figure(figsize=(11, 4.0))
dendrogram(matriz_enlace, truncate_mode="lastp", p=30, leaf_rotation=90,
           leaf_font_size=9, show_contracted=True, color_threshold=70)
plt.title("Dendrograma del agrupamiento jerarquico (enlace de Ward)")
plt.xlabel("Grupos; el numero entre parentesis indica cuantas observaciones agrupa")
plt.ylabel("Distancia de fusion (incremento de varianza)")
plt.tight_layout()
guardar("fig_dendrograma")

# Comparacion de criterios de enlace. Se comprueba una advertencia clasica: los
# enlaces average y complete pueden producir particiones degeneradas con
# siluetas enganosamente altas.
filas = []
for enlace in ["ward", "average", "complete"]:
    etiquetas = AgglomerativeClustering(n_clusters=3, linkage=enlace).fit_predict(Z)
    tam = np.bincount(etiquetas)
    filas.append({
        "Enlace": enlace,
        "Tamanos": " / ".join(str(t) for t in sorted(tam, reverse=True)),
        "Grupo mayor (%)": round(100 * tam.max() / len(Z), 1),
        "Silueta": round(silhouette_score(Z, etiquetas), 4),
        "ARI vs NSP": round(adjusted_rand_score(y_nsp, etiquetas), 4),
    })

comparacion_enlaces = pd.DataFrame(filas).set_index("Enlace")
print("Comparacion de criterios de enlace con k = 3:\n")
print(comparacion_enlaces.to_string())
print("\nLos enlaces average y complete logran siluetas muy superiores a ward,")
print("pero dejando mas del 99 % de las observaciones en un unico grupo. Una")
print("silueta alta con una particion degenerada NO indica un buen agrupamiento.")

jerarquico = AgglomerativeClustering(n_clusters=3, linkage="ward")
etq_jerarquico = jerarquico.fit_predict(Z)

print("\nWard definitivo (k = 3): tamanos %s, silueta %.4f"
      % (np.bincount(etq_jerarquico).tolist(), silhouette_score(Z, etq_jerarquico)))
[ ]
print("  ARI frente a NSP %.4f | ARI frente a K-Means %.4f (concordancia)"
      % (adjusted_rand_score(y_nsp, etq_jerarquico),
         adjusted_rand_score(etq_kmeans, etq_jerarquico)))

RES["comparacion_enlaces"] = comparacion_enlaces.reset_index().to_dict("records")
RES["ari_jerarquico"] = round(float(adjusted_rand_score(y_nsp, etq_jerarquico)), 4)
RES["ari kmeans vs jerarquico"] = round(float(adjusted rand score(etq kmeans, etq jerarquico)), 4)
```

```
Comparacion de criterios de enlace con k = 3:

                  Tamanos  Grupo mayor (%)  Silueta  ARI vs NSP
Enlace
ward      1097 / 942 / 87             51.6   0.1348      0.1793
average      2114 / 7 / 5             99.4   0.5188      0.0187
complete     2116 / 7 / 3             99.5   0.5749      0.0202

Los enlaces average y complete logran siluetas muy superiores a ward,
pero dejando mas del 99 % de las observaciones en un unico grupo. Una
silueta alta con una particion degenerada NO indica un buen agrupamiento.

Ward definitivo (k = 3): tamanos [942, 1097, 87], silueta 0.1348
  ARI frente a NSP 0.1793 | ARI frente a K-Means 0.3711 (concordancia)
```

Figura 14

Dendrograma del agrupamiento jerárquico con enlace de Ward

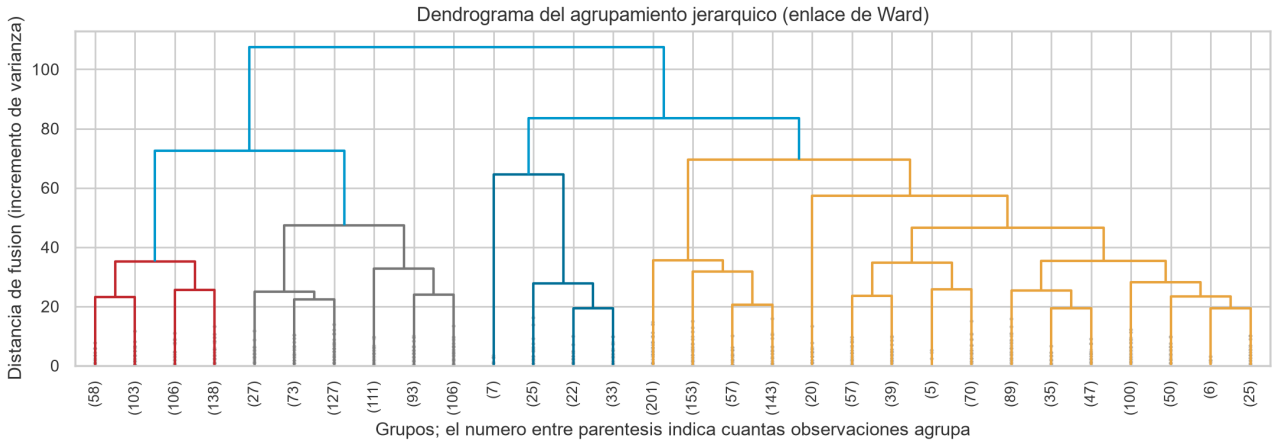

Nota. Se representan las últimas treinta fusiones. La altura de cada unión corresponde al incremento de varianza que provoca. Elaboración propia.

El dendrograma muestra un salto de altura claro en las últimas fusiones, compatible con dos o tres grupos, lo que respalda la elección de k igual a 3.

La comparación de criterios de enlace produce el aviso metodológico más importante de la sección. Los enlaces **`average`** y **`complete`** obtienen siluetas de 0,52 y 0,57, hasta cuatro veces mejores que las de Ward, que se queda en 0,13, pero lo consiguen dejando más del 99 % de las observaciones en un solo grupo y aislando dos grupitos de entre 3 y 7 puntos, con índices de Rand prácticamente nulos, de 0,02. Es la ilustración de que una métrica interna alta puede corresponder a un modelo inservible: la silueta premia particiones donde casi todo está junto y unos pocos puntos alejados forman grupos triviales.

Con Ward la partición es equilibrada, con 1 097, 942 y 87 observaciones, y su índice de Rand frente a **`NSP`** es de 0,179, algo inferior al 0,214 de K-Means. Curiosamente su información mutua normalizada es algo superior, 0,230 frente a 0,222: Ward capta algo más de información sobre el diagnóstico pero la reparte peor entre los grupos, que es lo que penaliza el índice de Rand. La concordancia entre ambas particiones es de 0,371, de modo que coinciden en lo esencial pero no son intercambiables, sobre todo en la frontera entre los dos grupos grandes.

6.6 Comparación global de los tres algoritmos

Listado 31. Celda 6.10. Comparacion final de los tres algoritmos de agrupamiento. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 6.10. Comparacion final de los tres algoritmos de agrupamiento.
# Objetivo: reunir en una sola tabla y en una sola figura los resultados de
#   K-Means, DBSCAN y jerarquico, con metricas internas y externas.
# Salidas: el DataFrame tabla_clustering y la figura fig_clustering_comparacion.

def evaluar_agrupamiento(nombre, etiquetas, espacio, requiere_k, maneja_ruido):
    """Calcula el bloque de metricas de un agrupamiento.

    El ruido, con etiqueta -1, se excluye de las metricas internas, ya que por
    definicion no constituye un grupo; si se incluyera penalizaria de forma
    artificial a DBSCAN frente a los algoritmos que particionan todo.
    """
    validos = etiquetas != -1
    n_grupos = len(set(etiquetas[validos]))
    sil = silhouette_score(espacio[validos], etiquetas[validos]) if n_grupos > 1 else np.nan
    db = davies_bouldin_score(espacio[validos], etiquetas[validos]) if n_grupos > 1 else np.nan
    return {
        "Algoritmo": nombre,
        "Grupos": n_grupos,
        "Sin asignar": int((~validos).sum()),
        "Silueta": round(sil, 4) if not np.isnan(sil) else None,
        "Davies-Bouldin": round(db, 4) if not np.isnan(db) else None,
        "ARI vs NSP": round(adjusted_rand_score(y_nsp, etiquetas), 4),
        "NMI vs NSP": round(normalized_mutual_info_score(y_nsp, etiquetas), 4),
        "Requiere k": "Si" if requiere_k else "No",
        "Detecta ruido": "Si" if maneja_ruido else "No",
    }
```

```python
tabla_clustering = pd.DataFrame([
    evaluar_agrupamiento("K-Means (k=3)", etq_kmeans, Z, True, False),
    evaluar_agrupamiento("DBSCAN (eps=2.0)", etq_dbscan, Z_dbscan, False, True),
    evaluar_agrupamiento("Jerarquico Ward (k=3)", etq_jerarquico, Z, True, False),
]).set_index("Algoritmo")

print("COMPARACION FINAL DE LOS ALGORITMOS DE AGRUPAMIENTO\n")
print(tabla_clustering.to_string())

fig, ejes = plt.subplots(1, 3, figsize=(12, 3.9))
particiones = [
    ("K-Means (k=3)", etq_kmeans),
    ("DBSCAN (eps=2.0)", etq_dbscan),
    ("Jerarquico Ward (k=3)", etq_jerarquico),
]
for eje, (nombre, etiquetas) in zip(ejes, particiones):
    for g in sorted(set(etiquetas)):
        m = etiquetas == g
        if g == -1:
            eje.scatter(Z2[m, 0], Z2[m, 1], s=12, c=UNIR_GRIS, marker="x", label="Ruido")
        else:
            eje.scatter(Z2[m, 0], Z2[m, 1], s=6, alpha=0.6, label="G%d" % g)
    eje.set_title("%s\nARI = %.3f" % (nombre, tabla_clustering.loc[nombre, "ARI vs NSP"]), fontsize=10)
    eje.set_xlabel("CP1"); eje.set_ylabel("CP2")
    eje.legend(fontsize=9, markerscale=1.8)
fig.suptitle("Los tres agrupamientos sobre el mismo plano de componentes principales", fontsize=12)
plt.tight_layout()
guardar("fig_clustering_comparacion")

RES["tabla_clustering"] = tabla_clustering.reset_index().to_dict("records")
```

```
COMPARACION FINAL DE LOS ALGORITMOS DE AGRUPAMIENTO

                        Grupos  Sin asignar  Silueta  Davies-Bouldin  ARI vs NSP  NMI vs NSP Requiere k Detecta ruido
Algoritmo
K-Means (k=3)                3            0   0.1572          1.9233      0.2142      0.2224         Sí            No
DBSCAN (eps=2.0)             2          213   0.3874          0.7396      0.1965      0.1340         No            Sí
Jerarquico Ward (k=3)        3            0   0.1348          2.0230      0.1793      0.2297         Sí            No
```

Figura 15

Los tres agrupamientos sobre el mismo plano de componentes principales

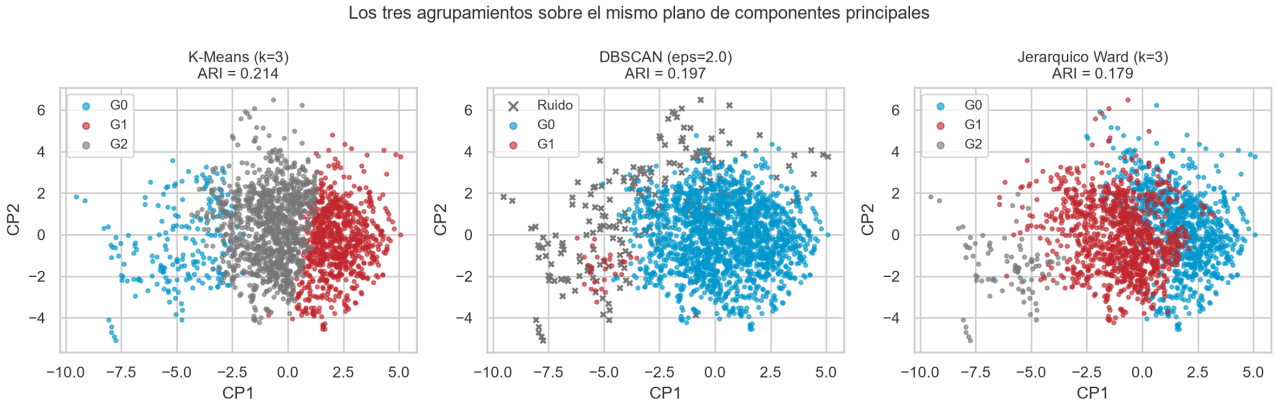

Nota. Bajo el nombre de cada algoritmo se indica su índice de Rand ajustado frente a la etiqueta NSP. Elaboración propia.

7. Ventajas y desventajas de cada modelo

7.1 Modelos de detección de anomalías

El Z-score es trivial de calcular e interpretar y su umbral tiene significado probabilístico directo. En contra: asume normalidad, es univariante e ignora las correlaciones, y su error acumulado crece con el número de columnas. Marcó el 16,1 % de las observaciones y, pese a un lift de 4,90, lo hizo a costa de demasiados falsos positivos.

La regla de Tukey no asume distribución, es robusta frente a valores extremos y es la base del diagrama de caja. Pero también es univariante y resulta inservible con fuerte asimetría o exceso de ceros, que es lo que ocurre aquí: marcó el 57,4 % con un lift de 1,65, de manera que no discrimina.

La distancia de Mahalanobis robusta es multivariante, tiene en cuenta la covarianza y su estimador de determinante mínimo evita el enmascaramiento que padecen la media y la covarianza muestrales. A cambio exige covarianza invertible, requisito que obligó a eliminar **`Width`**, asume normalidad multivariante y su coste crece de forma cúbica con el número de

variables. Obtuvo un lift de 5,01 al 5 %, aunque el gráfico cuantil-cuantil dejó claro que su supuesto no se cumple.

Isolation Forest no asume distribución, su coste es lineal, escala bien en dimensión alta y tiene pocos hiperparámetros. En contra: la contaminación debe fijarse a priori, el resultado varía con la semilla y sus cortes son paralelos a los ejes, lo que dificulta detectar estructuras oblicuas. Fue el mejor, con lift de 6,55, un 54,2 % de patológicos entre los marcados y un recall del 33 %.

El factor local de atipicidad es el único capaz de detectar anomalías locales y no impone forma global. En contra, la altísima sensibilidad al número de vecinos, la degradación de la densidad en dimensión alta y la imposibilidad de generalizar a datos nuevos sin activar el modo de novedad. Fue el peor de los multivariantes, con lift de 2,14.

7.2 Modelos de agrupamiento

K-Means es rápido y escalable, produce grupos interpretables mediante sus centroides y converge siempre. A cambio exige fijar el número de grupos, los supone esféricos y de tamaño similar, sus centroides no son robustos frente a atípicos y solo garantiza óptimos locales. Fue el mejor de los tres, con índice de Rand ajustado de 0,214 y tres fenotipos clínicamente coherentes.

DBSCAN no exige fijar el número, admite formas arbitrarias e identifica el ruido de manera explícita. Sus desventajas: enorme sensibilidad a eps y min_samples, fracaso cuando la densidad varía de forma continua y degradación en dimensión alta. Produjo dos grupos muy desiguales, de 1 885 y 28 observaciones, más 213 puntos de ruido, con índice de 0,197; útil como detector pero no como partición.

El jerárquico produce la jerarquía completa, de modo que el número de grupos se decide después, su dendrograma es muy interpretable y el resultado es determinista. En contra, el coste cuadrático en memoria y tiempo, la imposibilidad de deshacer una fusión y la fuerte dependencia del criterio de enlace. Con Ward obtuvo 0,179, mientras que **`average`** y **`complete`** degeneraron pese a siluetas mucho más altas.

7.3 Síntesis metodológica

De la comparación se desprenden tres lecciones. Las métricas internas no bastan: la silueta escogía dos grupos en K-Means, partición con índice de Rand de 0,016, y premiaba los enlaces degenerados del jerárquico con 0,52 y 0,57 pese a dejar el 99 % de los datos en un solo grupo. Sin referencia externa ni conocimiento del dominio, esos criterios habrían llevado a conclusiones erróneas.

Los supuestos distribucionales importan más que la sofisticación del método: los dos algoritmos que no asumen ninguna distribución, Isolation Forest y K-Means, fueron los mejores de su categoría, y en un conjunto fuertemente asimétrico.

Y la convergencia entre técnicas independientes es la mejor evidencia disponible. El grupo 0 de K-Means, el grupo 1 y el ruido de DBSCAN, y las anomalías de Isolation Forest apuntan al mismo

subconjunto de trazados: tres algoritmos con criterios distintos coinciden porque hay una estructura real que describir.

8. Conclusiones

Listado 32. Celda 8.1. Resumen ejecutivo de resultados y volcado a disco. Captura del cuaderno en Google Colab.

```
[ ]
# Celda 8.1. Resumen ejecutivo de resultados y volcado a disco.
# Objetivo: recapitular las cifras clave y guardar todos los resultados en
#   resultados.json, que es la fuente unica desde la que se genera el informe en
#   PDF. De este modo ninguna cifra del informe se transcribe a mano y no puede
#   desincronizarse del codigo.
# Salidas: el archivo resultados.json.

print("RESUMEN EJECUTIVO\n")
mejor = max(RES["tabla_anomalias"], key=lambda r: r["Lift"])
print("Datos      : %d registros analizados (de %d en el archivo), %d variables"
      % (RES["n_filas_final"],
         RES["n_filas_final"] + RES["n_filas_eliminadas"],
         RES["n_variables_modelo"]))
print("             %d filas eliminadas por ser filas de resumen de la hoja"
      % RES["n_filas_eliminadas"])
print("\nAnomalias  : Isolation Forest al 5 %%, %d observaciones marcadas"
      % mejor["Marcadas"])
print("             %.1f %% patologicos (tasa base %.1f %%), lift %.2f, recall %.1f %%"
      % (mejor["% patologicos"], 100 * RES["tasa_base_nsp3"],
         mejor["Lift"], mejor["Recall NSP=3"]))
print("\nAgrupamiento: K-Means con k = 3, grupos de %s observaciones"
      % " / ".join(str(v) for v in RES["tamanos_kmeans"].values()))
print("             silueta %.4f | ARI %.4f | NMI %.4f | pureza %.4f"
      % (RES["silueta_kmeans"], RES["ari_kmeans"],
         RES["nmi_kmeans"], RES["pureza_kmeans"]))


def convertir(objeto):
    """Convierte tipos de NumPy a tipos nativos serializables por json."""
    if isinstance(objeto, (np.integer,)):
        return int(objeto)
    if isinstance(objeto, (np.floating,)):
        return float(objeto)
    if isinstance(objeto, np.ndarray):
        return objeto.tolist()
    return str(objeto)


with open("resultados.json", "w", encoding="utf-8") as fh:
    json.dump(RES, fh, ensure_ascii=False, indent=2, default=convertir)

print("\nResultados guardados en 'resultados.json' (%d claves)." % len(RES))
print("Figuras guardadas en '%s/' (%d archivos)."
      % (DIR_FIGURAS, len(list(DIR_FIGURAS.glob("*.png")))))

RESUMEN EJECUTIVO

Datos      : 2126 registros analizados (de 2129 en el archivo), 20 variables
             3 filas eliminadas por ser filas de resumen de la hoja

Anomalias  : Isolation Forest al 5 %, 107 observaciones marcadas
             54.2 % patologicos (tasa base 8.3 %), lift 6.55, recall 33.0 %

Agrupamiento: K-Means con k = 3, grupos de 204 / 835 / 1087 observaciones
             silueta 0.1572 | ARI 0.2142 | NMI 0.2224 | pureza 0.7865

Resultados guardados en 'resultados.json' (42 claves).
Figuras guardadas en 'figuras/' (15 archivos).
```

8.1 Sobre el análisis exploratorio

El análisis exploratorio no fue un trámite previo sino que determinó todas las decisiones posteriores: descubrió que las tres últimas filas eran artefactos y no pacientes; que **`LBE`** duplica a **`LB`**, que **`DR`** es constante y que **`Width`** equivale exactamente a la diferencia entre **`Max`** y **`Min`**, redundancia que hacía singular la matriz de covarianzas e impedía calcular la distancia de Mahalanobis; y que las diez variables entre **`A`** y **`SUSP`** recodifican **`CLASS`**. De las 40 columnas iniciales solo 20 son descriptores genuinos.

El estudio de las distribuciones reveló asimetrías extremas y colas pesadas, lo que permitió anticipar y después confirmar que los métodos basados en normalidad rendirían peor que los no paramétricos.

8.2 Sobre el tratamiento de los valores faltantes

La respuesta correcta no consistía en elegir entre la media, la mediana o la moda, sino en reconocer que las filas afectadas no eran observaciones. Las 106 celdas faltantes se concentraban en 3 filas sin diagnóstico que resultaron ser las filas de resumen de la hoja de

cálculo original: una de mínimos y otra que reproduce el máximo de cada columna, coincidencia comprobada variable a variable. Imputarlas con la media habría fabricado tres pacientes ficticios, uno de los cuales alcanzaría a la vez el valor extremo de diez variables distintas, combinación que no se da en ningún trazado real, y habría contaminado tanto la detección de anomalías como los centroides de K-Means.

El experimento del apartado 3.3 responde a la pregunta general: cuando los faltantes son reales y dispersos, la mejor estrategia es la imputación por vecinos más cercanos, porque aprovecha la correlación entre variables, y la mediana es la mejor alternativa simple para las sesgadas. La media, que suele aplicarse por costumbre, distorsiona la forma de las distribuciones asimétricas, y la moda es la peor opción para variables continuas.

8.3 Sobre la detección de anomalías

Isolation Forest es el método elegido. Marcando solo el 5 % de los registros, el 54,2 % de los señalados resultaron patológicos frente a una tasa base del 8,3 %: un enriquecimiento de 6,6 veces y la recuperación de un tercio de los casos graves. Su perfil medio, con deceleraciones prolongadas y severas, variabilidad errática y bradicardia, reproduce la descripción clínica de un trazado no tranquilizador sin haber visto un solo diagnóstico.

Los métodos univariantes quedaron descartados por marcar el 16 % y el 57 % del conjunto. El factor local de atipicidad, pese a su sofisticación teórica, fue el peor de los multivariantes, porque en veinte dimensiones la densidad local pierde contraste y porque los casos patológicos no son puntos aislados sino una región periférica poblada que el método toma por un vecindario legítimo.

El bajo solapamiento entre métodos, con índices de Jaccard de 0,07 a 0,37, demuestra que ser una anomalía es una noción relativa al método. Elegir detector exige un criterio externo de utilidad; sin él la elección sería arbitraria.

8.4 Sobre el agrupamiento

K-Means con tres grupos es el modelo elegido, con índice de Rand ajustado de 0,214 frente a **`NSP`** y una prueba chi-cuadrado que descarta el azar. Los grupos admiten lectura clínica directa: uno tranquilizador de 1 087 registros con un 97,1 % de normales, otro de vigilancia de 835 registros con un 31 % de sospechosos y otro comprometido de 204 registros con un 51,5 % de patológicos, que concentra el 60 % de todos los casos graves.

DBSCAN no logró una partición útil porque los datos forman una nube única de densidad decreciente, sin los valles que necesita; aun así aisló un grupo de 28 casos íntegramente patológicos y su ruido coincide en un 46 %, por índice de Jaccard, con las anomalías de Isolation Forest. El jerárquico con Ward produjo una partición equilibrada y coherente, con 0,179, mientras que **`average`** y **`complete`** degeneraron pese a siluetas mucho más altas.

El valor moderado de todos los índices tiene explicación sustantiva y no metodológica: los algoritmos separan bien los extremos, pero la categoría de los sospechosos es una zona de

transición y no un fenotipo con frontera propia. Ningún método no supervisado puede recuperar una categoría que no forma grupo en el espacio de características.

8.5 Conclusión general

El aprendizaje no supervisado recupera estructura clínicamente válida en los datos de cardiotocografía: sin acceder a ningún diagnóstico, los algoritmos identificaron el subconjunto de trazados comprometidos y un gradiente de gravedad coherente con la clasificación obstétrica.

La conclusión práctica es que ambas técnicas son complementarias y no alternativas. Isolation Forest responde a qué registros concretos revisar con prioridad y K-Means a qué tipos de trazado existen en la población; un sistema de apoyo a la decisión clínica se beneficiaría de las dos, el agrupamiento para estratificar y la detección de anomalías para priorizar la revisión individual.

La lección metodológica de mayor alcance es que la calidad de un modelo no supervisado no puede juzgarse solo con métricas internas. En dos ocasiones el coeficiente de silueta habría conducido a la peor decisión posible: al elegir dos grupos en K-Means y al preferir los enlaces degenerados del jerárquico. El conocimiento del dominio y una referencia externa, cuando existe, son insustituibles.

Referencias

Ayres-de-Campos, D., Bernardes, J., Garrido, A., Marques-de-Sá, J., & Pereira-Leite, L. (2000). SisPorto 2.0: A program for automated analysis of cardiotocograms. *Journal of Maternal-Fetal Medicine, 9*(5), 311-318. https://doi.org/10.1002/1520-6661(200009/10)9:5<311::AID-MFM12>3.0.CO;2-9

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93-104. https://doi.org/10.1145/342009.335388

Calinski, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics, 3*(1), 1-27. https://doi.org/10.1080/03610927408827101

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224-227. https://doi.org/10.1109/TPAMI.1979.4766909

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226-231.

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193-218. https://doi.org/10.1007/BF01908075

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining*, 413-422. https://doi.org/10.1109/ICDM.2008.17

Meneses Yaranga, A. (2026). *Actividad de Aprendizaje Automático: detección de anomalías y técnicas de agrupamiento sobre el conjunto de datos CTG* [Código fuente]. GitHub. https://github.com/amenesesy/actividad-ml-ctg

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53-65. https://doi.org/10.1016/0377-0427(87)90125-7

Rousseeuw, P. J., & Van Driessen, K. (1999). A fast algorithm for the minimum covariance determinant estimator. *Technometrics, 41*(3), 212-223. https://doi.org/10.1080/00401706.1999.10485670

Rubin, D. B. (1976). Inference and missing data. *Biometrika, 63*(3), 581-592. https://doi.org/10.1093/biomet/63.3.581

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236-244. https://doi.org/10.1080/01621459.1963.10500845